

学校代码: 10246

学号: 20210240404

復旦大學

硕士学位论文

(专业学位)

面向多模态大模型能力提升的
数据合成框架研究

Research on a Data Synthesis Framework for Enhancing
Multimodal Large Language Models

院 系: 计算与智能创新学院

专业学位类别(领域): 计算机技术

姓 名: 郑国栋

指 导 教 师: 黄萱菁 教授

完 成 日 期: 2026 年 6 月 2 日

指导小组成员

黄萱菁 教授，张 奇 教授，桂 韬 副教授

目 录

插图目录	v
表格目录	vii
摘要	ix
Abstract	xi
符号表	xiii
第 1 章 绪论	1
1.1 研究背景	1
1.2 主要贡献	2
1.3 论文组织结构	4
第 2 章 相关工作	7
2.1 视觉-语言模型与多模态大模型	7
2.1.1 视觉表征学习与图文对齐预训练	7
2.1.2 从 VLM 到 MLLM: 生成式多模态模型的演进	7
2.1.3 结构化视觉输入的解析与推理	8
2.1.4 文本到图像生成与可控视觉合成	9
2.2 面向图形用户界面的多模态理解与智能体	9
2.2.1 GUI 截图的视觉特性与理解挑战	9
2.2.2 GUI 数据集与基准	10
2.2.3 GUI 智能体与计算机使用智能体	10
2.3 世界知识与多模态知识推理	11
2.3.1 知识型视觉问答基准	11
2.3.2 思维链推理与工具增强	11
2.3.3 指令微调与人类反馈对齐	12
2.3.4 事实性评测与检索增强生成	12
2.4 多模态数据合成与质量控制	13

2.4.1	高质量 Caption 与图文对齐数据	13
2.4.2	指令进化与代理式合成	13
2.4.3	合成数据的幻觉风险与质控机制	14
2.4.4	文本到图像的反向数据工程	14
2.5	已有工作进展与本文工作的差异化	15
2.5.1	已有工作进展归纳	15
2.5.2	本文相对已有工作的差异化贡献	15
第 3 章	面向用户图形界面的视觉语言模型能力提升	17
3.1	任务定义与核心挑战	17
3.1.1	基础能力: Referring 与 Grounding	17
3.1.2	三大核心挑战	17
3.1.3	研究目标与本章路线	18
3.2	本章核心方法概览	18
3.3	数据工程: 多源融合与高质量构建	20
3.3.1	GUI 数据构造流程	20
3.3.2	开源数据清洗与重构	23
3.3.3	闭源数据构建	24
3.4	模型架构与训练策略	27
3.4.1	视觉编码器与分辨率自适应: AnyRes 机制	27
3.4.2	坐标表示与定位 Token 设计: 文本化坐标生成	28
3.4.3	双阶段混合微调 (DMT): GUI 注入与通用对齐	28
3.5	实验与评估	29
3.5.1	评测任务与指标	29
3.5.2	实验结果与分析	29
3.6	本章小结	32
第 4 章	世界知识能力提升方案	35
4.1	任务定义与核心挑战	35
4.1.1	任务定义: 从“看见”到“理解”	35
4.1.2	三大核心困境	36
4.1.3	研究目标与本章路线	37
4.2	知识类别框架	37
4.3	数据工程: 世界知识数据构造 Pipeline	39
4.3.1	词条生成与图片收集: 从知识域到视觉证据	39
4.3.2	图片 Caption 生成: 融合视觉描述与知识背景	40

4.3.3	图文相关性过滤：保证视觉-知识对齐质量	41
4.3.4	QA 对生成：从描述到三元组任务	42
4.3.5	QA 对质量过滤：确保训练数据可靠性	44
4.4	训练与实验：从数据类型消融到 CoT 对齐	45
4.4.1	多阶段、多来源数据构建	45
4.4.2	实验一：数据类型消融与冲突分析	45
4.4.3	实验二：引入 Think/CoT 与数据扩充的改进效果	46
4.4.4	最终结果：Chinese SimpleVQA 与 SimpleVQA	47
4.5	本章小结	48
第 5 章	多模态数据合成框架	51
5.1	研究动机与本章路线	51
5.1.1	从两端实证到共通骨架	51
5.1.2	研究目标与本章路线	52
5.2	构造框架	52
5.2.1	构造流程	52
5.2.2	从两类任务实践到统一框架的归纳	57
5.3	模块有效性验证	59
5.4	Auto-Evol 在 GUI CUA 领域的实例化	60
5.4.1	流程概览与 Auto-Evol 模块对应	60
5.4.2	与 Auto-Evol 在多模态合成场景下的差异化贡献	62
5.4.3	基于 Auto-Evol 合成数据的端到端训练验证	63
5.5	本章小结	65
第 6 章	结论	67
6.1	研究总结	67
6.2	主要成果与创新点	68
6.3	不足与展望	69
6.3.1	研究不足	69
6.3.2	展望	70
	参考文献	71

插图目录

1-1	本文研究架构概览：上层为研究问题与核心主张；中部为“数据能力光谱”两端——第 3 章 GUI 数据工程（感知端）与第 4 章世界知识数据工程（推理端）；下层为从两端归纳的共通骨架及其抽象为 Auto-Evol 框架（第 5 章），并以 GUI CUA 端到端 SFT 实验验证。	3
3-1	GUI 数据合成 Pipeline 全景图：4 阶段 + 失败回流闭环。上层为多源输入（开源/闭源/合成）；中部依次为结构化初始化（1000 级坐标量化）、人机协同混合标注（自动预标注 + 23 类分类学/关系图谱/状态向量三件套标注规范）、三类 QA 合成（Task Grounding / State Transition / Referring 双向）、质控与二级去重；下层为训练阶段对应的 AnyRes + 文本化坐标 + DMT 策略。	22
4-1	有无世界知识的模型响应对比。无世界知识：“一个男人和一个女人站在船头。”有世界知识：“这是 1997 年上映的电影《泰坦尼克号》的经典海报，由詹姆斯·卡梅隆执导，主演是莱昂纳多·迪卡普里奥和凯特·温斯莱特……”	36
4-2	世界知识类别框架（7 个大类与 40 个子类）。	38
4-3	世界知识数据构造 Pipeline。	40
4-4	Caption 数据示例（电影《1917》相关画面）。	41
4-5	三类 QA 与 FinalQA with CoT 示例（格鲁/Gru）。	44
5-1	Auto-Evol 多模态合成数据闭环 Pipeline：数据初始化（含标注）-过滤-原子问题生成-增强与校验-回流重写。	53

表格目录

3-1	第 3 章 GUI 挑战、本文核心方法（创新点 C1–C6）与对应实验验证总览。“二级近重复去重”为质控阶段的辅助手段，不计入 6 项核心创新；C1（三类训练任务联合监督）作为数据侧基础设计贯穿三大挑战，其整体收益在表 3-2 的多源数据消融中体现。	19
3-2	不同数据配置下的 Grounding 与 Referring 性能对比。	30
3-3	各类型 UI 控件的 Grounding 性能（F1 Score）。	31
3-4	Referring 任务各属性预测性能。	32
4-1	不同图文相关性过滤策略下的样本保留与 caption 幻觉程度统计（括号内为占比，保留 1 位小数）。	42
4-2	实验一：Part1 数据与不同数据类型配置的消融结果（Chinese SimpleVQA）。Rec 表示 Recognition；Acc 表示 Accuracy；Part1 表示第一批数据；all 表示全部类型数据；e 表示训练轮次；RKF 分别表示 RecQA、KnowQA 与 FinalQA。	46
4-3	实验二：引入 Think/CoT 与数据扩充后的改进结果（Chinese SimpleVQA）。Part12/Part123 表示逐步扩充的数据批次；think 表示 FinalQA 带推理过程的训练设置；Gap 为最优模型相对 Qwen2.5-VL-7B 的提升。	47
4-4	最终结果：Chinese SimpleVQA。Gap 为 Ovis2.5_9B 相对 Qwen2.5-VL-7B 的增益。	48
4-5	最终结果：SimpleVQA。Gap 为 Ovis2.5_9B 相对 Qwen2.5-VL-7B 的增益。	48
5-1	基于 Auto-Evol GUI CUA 合成数据训练前后，Qwen3-VL-Think 在 OSWorld LibreOffice 三个领域上的 reward 对比。Calc/Impress/Writer 列为领域级 reward 绝对总和（满分 = 该领域任务数），Overall 为 3 领域总和占 117 题的总体准确率（%）。	64

摘要

多模态大语言模型近年来快速发展，但其能力提升正越来越受限于训练数据的质量、对齐度与推理密度。互联网抓取的图文对噪声较大、对齐较弱；人工标注成本高、长尾覆盖有限；模型在真实任务中暴露出小目标定位不稳、视觉证据与语言描述绑定松散、推理任务易出现短路映射等结构性误差。“数据规模优先”的合成范式已遇瓶颈，亟需面向质量与能力维度的系统化数据生产方法。

本文研究如何以可控、可迭代、可验证的方式生产高质量多模态训练数据，并沿数据能力光谱的感知端、推理端与综合中段三个代表性位置展开实证。在感知端面向图形用户界面（GUI）任务，构建以多源融合为核心的数据合成流水线，结合紧致边界框、光学字符识别（OCR）对齐、控件关系图谱与状态向量等结构化监督，并配合动态分辨率感知（AnyRes）与双阶段混合微调策略，在覆盖前 200 主流应用真实分布的内部评测集上将视觉定位 F1 分数由 0.324 提升至 0.846、指代识别 F1 分数由 0.523 提升至 0.905。在推理端面向世界知识任务，建立 7 大类 40 子类知识类别框架与端到端数据流水线，通过“词条 → 图片 → 图像描述 → 相关性过滤 → 识别问答（RecQA）/知识问答（KnowQA）/综合问答（FinalQA）”链路将分散知识转化为可学习、可校验的多模态监督，并在综合问答中引入思维链（Chain-of-Thought, CoT）过程监督以缓解短路映射，在 Chinese SimpleVQA 与 SimpleVQA 上取得有竞争力的结果。

在两端工程实践基础上，本文进一步抽象提出 Auto-Evol 多模态数据合成框架，将以往单步生成升级为包含数据源接入、结构化初始化、质量过滤、原子问题生成、数据增强、多维校验与失败回流共七个模块的闭环系统，以“感知/理解/推理”三能力为统一坐标系。为验证框架的可迁移性，本文将其实例化到光谱综合中段的图形用户界面计算机使用智能体（GUI CUA）场景，依托 OSWorld 评测体系在 LibreOffice 三个应用领域上构建可验证任务合成系统；通过 900 合成任务、723 成功轨迹与 3 万条单步训练数据，将 Qwen3-VL-Think 模型在 OSWorld LibreOffice 三个领域上的总体准确率由 40.8% 提升至 61.4%，绝对增益 20.6 个百分点。所提方法与框架为多模态数据合成在更多任务域的复用与扩展提供了可参考的工程范式。

关键词：多模态大模型；数据合成；Auto-Evol 框架；图形用户界面智能体；世界知识

中图分类号：TP391

Abstract

Multimodal large language models (MLLMs) have advanced rapidly in vision–language understanding, but their capability ceiling is increasingly constrained by the quality, alignment, and reasoning density of training data rather than data scale. Web-crawled image–text pairs are noisy and weakly aligned; manual annotation is expensive and narrow in long-tail coverage; models exhibit structural errors such as unstable small-object localization, loose vision–language grounding, and shortcut learning on reasoning tasks. Under this bottleneck, the traditional “scale-first” synthesis paradigm is no longer sufficient.

This thesis investigates how to produce high-quality multimodal training data in a controllable, iterative, and verifiable manner, organized along three representative positions on the data capability spectrum: the perception end, the reasoning end, and the synthetic mid-band. At the perception end, targeting mobile GUI tasks, we build a multi-source data synthesis pipeline with structured supervision (tight bounding boxes, OCR alignment, element relation graphs, interaction states), combined with AnyRes high-resolution perception and dual-stage mixed tuning. On an internal evaluation set covering the real-world distribution of top-200 popular applications, this raises Grounding F1 from 0.324 to 0.846 and Referring F1 from 0.523 to 0.905. At the reasoning end, targeting world-knowledge tasks, we construct a taxonomy of 7 super-categories and 40 sub-categories with an end-to-end pipeline (entry $\rightarrow$ images $\rightarrow$ captions $\rightarrow$ relevance filtering $\rightarrow$ RecQA/KnowQA/FinalQA), and introduce Think/CoT process supervision in FinalQA to mitigate shortcut learning, achieving competitive results on Chinese SimpleVQA and SimpleVQA.

Generalizing recurring patterns from both ends, we propose Auto-Evol, a closed-loop multimodal data synthesis framework with seven modules—data sourcing, structured initialization, quality filtering, atomic-question generation, data augmentation, multi-dimensional validation, and feedback rewriting—organized around the perception/understanding/reasoning capability axes. To validate transferability, we instantiate Auto-Evol on the synthetic mid-band—GUI Computer Use Agent (CUA) tasks—and build a verifiable-task synthesis pipeline on three OSWorld LibreOffice domains under the OSWorld benchmark. With 900 synthetic tasks, 723 successful trajectories, and 30k

single-step training samples, Qwen3-VL-Think achieves an overall accuracy improvement from 40.8% to 61.4% (+20.6 points). The proposed methodology and framework provide a reusable engineering paradigm for multimodal data synthesis across broader task domains.

Keywords: Multimodal Large Language Models; Data Synthesis; Auto-Evol Framework; GUI Agent; World Knowledge

CLC code: TP391

符号表

$\mathbb{R}$	实数集
$\mathbb{N}$	自然数集
$\mathcal{D}$	数据集
$\mathcal{L}$	损失函数
IoU	交并比 (Intersection over Union)
B_{pred}	预测边界框 (Predicted bounding box)
B_{gt}	标注/真值边界框 (Ground-truth bounding box)
τ	阈值 (如 IoU 判定阈值)
$[l, t, r, b]$	边界框坐标表示 (左、上、右、下)
R_{ext}	外部注释到控件的绑定关系 (Label-to-Control)
R_{val}	当前值到控件的绑定关系 (Value-to-Control)
x	输入数据
y	输出结果
$f(\cdot)$	映射函数
θ	模型参数
AI	人工智能 (Artificial Intelligence)
ML	机器学习 (Machine Learning)
DL	深度学习 (Deep Learning)
CNN	卷积神经网络 (Convolutional Neural Network)
GAN	生成对抗网络 (Generative Adversarial Network)
GUI	图形用户界面 (Graphical User Interface)
VLM	视觉语言模型 (Vision-Language Model)
MLLM	多模态大语言模型 (Multimodal Large Language Model)
OCR	光学字符识别 (Optical Character Recognition)
SFT	监督微调 (Supervised Fine-Tuning)
CoT	链式思维 (Chain-of-Thought)
QA	问答 (Question Answering)
RecQA	识别问答 (Recognition QA)

KnowQA	知识问答 (Knowledge QA)
FinalQA	推理问答 (Reasoning QA)
DMT	双阶段混合微调 (Dual-stage Mixed Tuning)
AnyRes	动态分辨率/任意分辨率机制 (Any Resolution)

第 1 章 绪论

1.1 研究背景

多模态大语言模型（Multimodal Large Language Model, MLLM）近年来在视觉理解与语言生成方面取得显著进展^[1-4]，并逐步从通用图文理解走向真实应用形态的智能体（Agent）与复杂推理任务^[5-7]。在这一阶段，模型能力的上限越来越受制于训练数据的质量、对齐与推理密度，而不仅仅是数据规模：互联网抓取的图文对普遍存在噪声大、语义对齐弱、图像质量参差不齐等问题^[8-10]；人工标注虽然可靠，但成本高且难以覆盖长尾场景、复杂交互形态与多步推理链路^[11-12]。与此同时，模型在真实落地任务中暴露出的误差模式往往具有“结构性”：例如对小目标与文字细节不稳定^[13-14]、对视觉证据与语言描述的绑定松散^[15]、对需要先识别再推断的任务易出现短路映射或幻觉^[16-17]。这些结构性误差表明，仅靠扩规模已经难以系统性地提升模型在关键能力维度上的表现^[18-20]——数据质量正在取代数据规模成为多模态模型的能力瓶颈。

针对这一瓶颈，本文的核心主张是：多模态数据生产不应被视为“生成一些图文/问答对”的单步过程，而应被组织为一个面向能力提升的闭环系统——以可控、可迭代、可验证的方式持续产出高信息密度、高对齐度与高推理密度的训练信号。该系统需同时回应模型的三类基础能力——感知（看得清、定位稳）、理解（看得懂、绑得牢）与推理（想得全、链得通），并通过数据源接入 → 结构化初始化 → 质量过滤 → 任务原子化生成 → 数据增强 → 多维校验 → 失败回流的全链路前置约束训练信号质量。换言之，本文要把以往“零散的一次性合成”升级为“闭环可迭代的合成系统”。

要验证上述主张，本文不选择“在通用图文任务上做小幅改进”的常规路线，而是选择**多模态数据能力光谱的两端场景**作为实证支点，使共通的数据工程骨架在两端之间自然涌现（如图1-1所示）。其中，**感知端**对应面向图形用户界面（Graphical User Interface, GUI）的高精度可执行监督（第3章）：GUI任务（涵盖移动端与桌面端用户界面）以控件密集、文字细小、状态易变为特征^[13,21-22]，其监督必须细到像素、对到字段、绑到状态——模型需在指代识别（Referring）与视觉定位（Grounding）等任务中输出可执行的目标位置，因此构成数据能力光谱的“高精度、低知识、强可执行”一端^[14,23-26]。**推理端**则对应面向世界知识的可验证对齐与过程推理（第4章）：世界知识（World Knowledge）任务要求模

型把图像中的具体实例锚定到知识空间的抽象实体与事实^[16,27-28]，并在多跳条件约束下完成“先识别 → 再检索 → 再筛选”的推理链路^[29-31]；其数据工程的关键不是像素级精度，而是语义级可验证对齐与过程性监督——训练样本必须可核验、答案必须唯一、推理链路必须显式^[15,17,32-33]，因此构成光谱的“高知识、需推理、弱像素约束”一端。两端的策略性互补使得二者并非“两件不相关的事”，而是把多模态数据需求拉到了能力光谱的两端：GUI 解决“看得准、点得稳”，世界知识解决“懂得对、推得通”。在两端的真实工程实践中，数据源组织、结构化初始化、任务分解与生成、增强/过滤/多维校验、失败回流与闭环迭代等模块以高度一致的形态反复出现，这正是本文得以将其抽象为统一框架的实证基础。

除两端之外，许多真实任务同时需要感知与推理两类能力的协同——例如计算机使用智能体（Computer Use Agent, CUA）场景下的 GUI 任务（GUI CUA），其完整动作链同时要求模型看清当前界面控件状态（感知）、规划多步操作序列（推理）与跟踪动态状态转移三者协同，因而处于数据能力光谱的**综合中段**。基于两端的工程实践与共通模式归纳，本文在第3章与第4章分别给出 GUI 与世界知识两条数据工程主线，并在第5章进一步将二者共通的骨架抽象为 **Auto-Evol 多模态数据合成框架**；在框架抽象之上，本文还将该框架实例化到 GUI CUA 综合中段场景，依托 OSWorld 评测体系^[6]构建可验证任务合成的工程系统，并通过端到端“合成任务 → 轨迹采集 → 单步拆分 → 监督微调（Supervised Fine-Tuning, SFT）”实验提供 Qwen3-VL-Think 在 OSWorld LibreOffice 三个领域上 40.8%→61.4%（+20.6 pt）的量化证据，与 EvoCUA^[34]等近期工作形成互补。图1-1给出了本文研究问题、两端主线与统一框架之间的关系，全文章节按“两端实证 → 共通抽象 → 综合中段端到端验证”的顺序展开。

1.2 主要贡献

本文围绕“多模态数据合成框架”这一主线，沿数据能力光谱的三个代表性位置（感知端 / 推理端 / 综合中段）展开“两端实证 → 共通抽象 → 综合中段端到端验证”的研究路径，主要贡献总结为三点：

- 感知端：面向 GUI 的高质量数据工程与可执行定位能力提升方案（精细但强约束的合成/标注范式）：针对 GUI “控件密集、文字细小、状态易变”的特征，构建多源融合的数据 Pipeline 与结构化监督信号（bbox / OCR / 关系 / 状态），并结合高分辨率感知与训练策略提升 Referring 与 Grounding 两项核心能力；该部分更偏向“相对原始但精细”的数据合成与标注工程，为后续更复杂任务的监督设计提供可复用的监督原子与质控方法（如表3-2、表3-3与表3-4所示）。




图 1-1 本文研究架构概览：上层为研究问题与核心主张；中部为“数据能力光谱”两端——第3章 GUI 数据工程（感知端）与第4章世界知识数据工程（推理端）；下层为从两端归纳的共通骨架及其抽象为 Auto-Evol 框架（第5章），并以 GUI CUA 端到端 SFT 实验验证。

- 推理端：面向世界知识的可控对齐与推理贯通数据体系（增强与反向对齐的更先进合成范式）：构建覆盖广、可扩展的世界知识类别框架，并设计“词条 → 图片 → caption → 相关性过滤 → 三类 QA”的数据 Pipeline；引入数据增强与从答案出发的反向对齐流程，提升“视觉证据 ↔ 知识事实”的可验证性；进一步通过带推理过程（Think/CoT）的 FinalQA 缓解短路映射与任务冲突，专项 SFT 设置下推理指标相对 Qwen2.5-VL-7B 显著提升（表4-3，F1_Final +11.9 pt），最终在 Chinese SimpleVQA 与 SimpleVQA 上取得有竞争力的整体结果（表4-4与表4-5）。
- 共通抽象 + 综合中段端到端验证：Auto-Evol 多模态数据合成框架及其 GUI CUA 实例化：在两端数据合成范式的差异与共通点之上，抽象出一套面向能力提升的通用数据合成流程，统一刻画数据源接入、结构化初始化、质量过滤、任务路由与原子问题生成、数据增强、多维校验、失败回流重写共七个关键模块，使高信息密度、高对齐度与高推理密度的数据能够被稳定、迭代地产出与复用（对应第5章的整体框架与模块设计）；进一步将该框架实例化到综合中段——GUI 计算机使用智能体（Computer Use Agent, CUA）场景（多步操作链 + 动态状态跟踪），依托 OSWorld^[6]评测体系，在 LibreOffice 三个领域（Calc/Impress/Writer）上完成端到端验证，并已沿用同一套 Pipeline 骨架向 VSCode、Chrome 等扩展领域拓展，与近期 EvoCUA^[34]等代表性工作形成互补；端到端训练实验进一步证实其有效性——基于本框架合成的 900 任务、723 成功轨迹与 3 万条单步训练数据，将 Qwen3-VL-Think 在 OSWorld LibreOffice 三个领域上的总体准确率由 40.8% 提升至 61.4%（绝对增益 +20.6 pt，详见5.4节与表5-1）。

1.3 论文组织结构

本文的组织结构如下：

第一章（绪论）介绍研究背景、问题动机与本文的主要贡献，并给出全文组织结构。

第二章（相关工作）回顾视觉-语言模型与多模态大模型的发展脉络，以及 GUI 理解、世界知识增强与多模态数据合成相关研究，为本文方法设计提供背景支撑。

第三章（面向 GUI 的能力提升——感知端实证）围绕 Referring 与 Grounding 两项核心能力，给出 GUI 场景的数据工程 Pipeline、结构化监督设计与训练策略（如高分辨率感知与双阶段混合微调），并通过控件级评测验证方法有效性（第3章）。该章对应数据能力光谱的感知端，聚焦“精细但强约束”的数据合成

与标注流程，为后续章节的更复杂合成提供方法基座。

第四章（世界知识能力提升——推理端实证）构建世界知识类别框架与端到端数据 Pipeline，提出 RecQA/KnowQA/FinalQA 的任务分解，并通过引入数据增强、反向对齐与 Think/CoT 等过程性监督提升“先识别再推理”的世界知识推理能力（第4章）。该章对应数据能力光谱的推理端，相较 GUI 进一步强调对齐可信与推理贯通，为统一框架抽象提供更丰富的模块形态。

第五章（多模态数据合成框架——共通抽象 + 综合中段端到端验证）在第三、四章两类数据合成范式的对比与互补基础上，提炼共通机制与可改进方向，进一步抽象提出 Auto-Evol 多模态数据合成框架，系统阐述闭环 Pipeline 及其关键模块，并结合实验现象对核心设计进行归因式验证；在框架抽象之上，本章还将 Auto-Evol 实例化到综合中段的 GUI CUA 场景，基于 OSWorld 评测体系^[6]构建可验证任务合成的工程系统，在 LibreOffice 三个领域上完成端到端验证，并已沿用同一套 Pipeline 骨架向 VSCode、Chrome 等扩展领域拓展，通过“合成任务 → 轨迹采集 → 单步拆分 → SFT”的端到端实验给出量化证据（Qwen3-VL-Think 总体准确率 +20.6 pt），与 EvoCUA^[34]等代表性工作形成方法学层面的互补。

第六章（结论）总结全文工作与主要结论，分析研究不足，并展望未来研究方向。

第 2 章 相关工作

2.1 视觉-语言模型与多模态大模型

视觉-语言模型 (Vision-Language Model, VLM) 的发展经历了从“以视觉编码器为核心的表征学习”到“视觉-语言对齐的基础模型”，再到“面向复杂任务的多模态指令跟随与推理”的演进。本文的研究问题（多模态数据合成框架）与后续两条任务线（GUI、世界知识）都建立在这一演进脉络之上，因此本节重点回顾与本文最相关的 VLM 与多模态大语言模型 (MLLM) 的关键路线。

2.1.1 视觉表征学习与图文对齐预训练

视觉表征学习是多模态模型的基础。早期的视觉模型主要依赖卷积神经网络 (CNN) 进行特征提取，其中以残差网络 (ResNet) 为代表的架构通过更深网络与稳定训练显著提升了表征能力^[35]。随后，Vision Transformer (ViT) 将 Transformer 架构引入视觉领域，通过将图像切分为 Patch 序列进行处理，强化了对全局上下文的建模能力，并推动了“以预训练规模驱动性能”的范式^[36]。

在此基础上，对比学习 (Contrastive Learning) 成为视觉与语言建立共享语义空间的重要途径。CLIP 通过海量图文对进行对比学习，使模型获得了强迁移的视觉表示能力，并在零样本分类等任务上表现突出^[37]。与 CLIP 相近的路线还包括 ALIGN 等工作，强调“弱噪声文本监督 + 更大规模数据”的可扩展性，从而进一步巩固了开放词表视觉语义对齐的可行性^[38]。这类方法的关键贡献在于将视觉表征从“固定类别监督”转向“语言可描述的开放世界概念”，为后续多模态生成式建模提供了通用的语义对齐基础；同时也提示了一个事实：模型能力上限往往由数据覆盖度与噪声控制能力共同决定。

2.1.2 从 VLM 到 MLLM：生成式多模态模型的演进

随着大语言模型 (LLM) 能力的爆发，主流路线逐渐从“检索/匹配式 VLM”走向“以 LLM 为核心的生成式 MLLM”。这一范式利用视觉编码器提取视觉特征，通过适配器 (Adapter) 映射到 LLM 的词嵌入空间，最终由 LLM 统一完成理解、生成与推理。

Flamingo 采用了在冻结的 LLM 中插入交叉注意力层 (Cross-Attention) 的架构，并在海量交错图文数据上进行训练，展示了在少样本条件下的强大通用能

力^[39]。BLIP-2 进一步提出了 Q-Former 结构，通过一组可学习的 Query 向量与图像编码器交互，实现了更高效的跨模态桥接，在保持训练效率的同时获得了强泛化能力^[40]。

在“指令跟随 (Instruction Following)”框架下，多模态模型通过视觉指令微调 (Visual Instruction Tuning) 进一步获得了更好的对话式交互能力。LLaVA 系列工作系统化探索了视觉指令微调的数据构造与训练策略，证明了简单的线性映射或 MLP 即可实现高效的模态对齐^[4,41]。与此并行的路线还包括：基于“统一理解与生成”的 BLIP 框架^[42]，以及面向指令调优的 InstructBLIP 等工作^[43]，它们都强调通过更结构化的监督信号让模型输出更可控、更贴近真实任务分布。

当训练规模进一步扩大时，PaLI 等工作展示了“语言与图像共同扩展”的另一条路径，即通过多语种与多任务的联合扩展获得更强泛化^[44]。此外，GPT-4o 等原生多模态模型 (Native Multimodal Models) 的出现，进一步打破了模态间的界限，实现了端到端的跨模态理解与生成^[1]；Gemini 等技术报告也表明，面向实际交互的多模态能力（如工具使用、长上下文、多步推理）正在成为系统级目标^[2]。总体而言，这一阶段的核心变化是：模型能力的瓶颈逐渐从“是否能对齐视觉与语言”转向“是否具备足够高质量、可控结构的监督信号”，而数据构造与质控机制开始与模型架构同等重要。

近年来，先进 MLLM 进一步将能力边界推向“长上下文 + 视频 + 代理 (agent)”的综合场景。一方面，Gemini 系列与 GPT-4o 代表了闭源原生多模态系统在实时交互与端到端建模上的方向^[1-2]；另一方面，开源侧也在快速演进，例如 Qwen3-VL 系列通过更长上下文与更强的视频/交错多模态建模能力增强复杂任务覆盖^[45]，而 MiMo-VL 等工作则探索将大规模预训练与强化学习式对齐结合，以在推理、GUI/agent 等任务上获得更强的可执行性与鲁棒性^[46]。

2.1.3 结构化视觉输入的解析与推理

除通用图文理解外，图表、文档、截图等“结构化视觉输入”对模型的视觉解析与逻辑推理提出了更高要求。这类数据通常包含密集的文本信息和复杂的布局结构，单纯的图像描述 (Captioning) 往往难以涵盖其全部语义。

ChartQA 提出了包含视觉与逻辑推理的图表问答基准，推动模型从简单的“读图”走向复杂的“推断”^[47]。DePlot 创新性地 will 图表理解转化为“图到表”的结构化转换任务，从而以可执行的中间表征（表格）支撑后续的符号推理^[48]；MatCha 进一步引入了数学推理与图表反渲染 (De-rendering) 机制来增强预训练效果^[49]。Pix2Struct 则提出将“截图解析”作为预训练任务，强调对 UI、网页等截图的结构化 HTML/DOM 树恢复能力^[50]。这些工作共同表明：当任务依赖结构化信息（布局、文本、关系）时，需要更强的结构化中间表示与针对性的数据

构造策略。

2.1.4 文本到图像生成与可控视觉合成

在图像生成方向，扩散模型（Diffusion Models）推动了高分辨率、高保真生成能力的快速发展。以 SDXL 为代表的高质量扩散模型显著提升了高分辨率图像合成的质量与细节表现^[51]，为“文本 → 图像”的反向数据工程提供了坚实的工具体系。对于本文的研究而言，生成模型的价值不仅在于生成图像本身，更在于为多模态数据合成提供可控的视觉证据（Visual Evidence），从而能够以低成本的方式弥补真实数据在长尾场景下的稀缺性以及图文弱对齐的问题。

2.2 面向图形用户界面的多模态理解与智能体

面向图形用户界面（GUI）的视觉理解与交互是多模态模型落地的重要方向之一。与自然图像相比，GUI 截图具有控件密集、文字细小、布局强结构化与状态易变等特征，使得模型需要同时具备细粒度视觉感知能力（小目标定位、OCR 相关细节）、结构化理解能力（控件关系、层级与语义绑定）以及可执行输出能力（产生可解析的坐标或动作序列）。

2.2.1 GUI 截图的视觉特性与理解挑战

GUI 图像与自然场景图像存在显著差异，其挑战不仅来自视觉观测本身，也来自“可执行交互”所要求的结构化与可控输出。首先，GUI 界面通常包含大量细小的图标与高密度文本（按钮、菜单、表格、提示信息等），这要求模型具备更高分辨率的细粒度感知与稳定的 OCR/文本检测能力；在工程实践中，轻量 OCR 系统（如 PP-OCR）常被用作 GUI 理解链路中的关键组件^[14]。其次，GUI 语义强依赖布局与层级关系（DOM 树、View Hierarchy、可访问性树 A11y 等），因此仅基于图像级描述往往不足，需要“像素 → 结构”的解析能力来恢复可执行的中间表示。Pix2Struct 通过将截图解析作为预训练目标，验证了结构化表示对截图类输入的增益^[50]。

进一步地，GUI 任务的核心输出通常不是自然语言描述，而是可执行动作（点击/输入/滚动等）及其对应的目标元素定位，这使得元素级 grounding 成为能力瓶颈之一。SeeClick 等工作专门聚焦 GUI 点击与定位，强调更严格的坐标/区域监督与视觉指向能力^[13]；OS-ATLAS 则从跨平台角度提出统一动作空间与大规模定位语料，推动模型在不同操作系统与界面风格上的泛化^[5]。

最后，真实 GUI 交互具有动态性与多步性：界面状态随操作而变化，且任务往往需要“观察 → 规划 → 执行 → 纠错”的闭环。GUI-WORLD 等数据集面向动态 GUI 内容与多场景任务构建评测，揭示了仅凭单帧理解的局限^[26]；GUICourse

提出从通用 VLM 到 GUI 智能体的分阶段数据与训练范式，强调 OCR、GUI 知识与交互能力的递进式培养^[24]。同时，面向 GUI 智能体的系统性综述也指出：数据基础设施、评测协议与错误恢复机制正在成为影响落地可靠性的关键因素^[7]。

2.2.2 GUI 数据集与基准

高质量的数据集是推动 GUI 理解发展的关键。Rico 数据集是早期最具代表性的移动端 UI 数据集，包含了大量 Android 应用截图及其对应的视图层级数据，为 UI 设计检索和布局生成提供了基础^[21]。然而，原始的 Rico 数据存在大量噪声和缺失。Clay 进一步提出了基于学习的方法来对原始 UI 布局进行去噪和修复，显著提升了数据的可用性^[23]。

近期，随着大模型对数据规模需求的增加，MobileViews 构建了百万量级的移动端 GUI 数据集，涵盖了更广泛的应用场景和界面类型^[22]。此外，为了支持动态交互任务，DroidBot 等自动化测试工具被广泛用于通过随机或策略性探索来收集动态的 UI 交互轨迹^[52]。这些数据集的演进反映了从“静态布局分析”向“动态交互理解”的趋势。

2.2.3 GUI 智能体与计算机使用智能体

在模型层面，研究者们致力于构建能够像人类一样操作设备的 GUI 智能体。Pix2Struct 通过将截图解析任务作为预训练目标，证明了从像素中恢复结构化表示（如 HTML）能够有效提升模型对 UI 的理解能力^[50]。

更进一步，OS-Atlas 提出了通用的 GUI 动作模型（Action Model），通过在海量跨平台 GUI 数据上进行从粗粒度到细粒度的动作预测训练，实现了对不同操作系统（移动端、桌面端）的泛化控制能力^[5]。这类工作的核心在于将视觉感知与动作空间（如点击、滑动、键盘输入）进行对齐，使模型不仅能“看懂”界面，还能“操作”界面。这一观察与本文第3章采用的多源融合、结构化标注与质控迭代思路一致，即通过高质量的合成数据来弥补真实交互数据的稀缺性。

除了移动端与桌面端，Web 场景为 GUI 智能体提供了更开放、可复现的评测环境。World of Bits（MiniWoB 等）通过将网页交互任务抽象为一组可自动评测的微任务，推动了从“脚本/规则自动化”向“学习型交互策略”的转变^[53]。随着任务难度上升，Mind2Web 等工作开始关注真实网页上的长程任务与多步决策，强调智能体在开放网页环境下的泛化与鲁棒性^[54]；WebArena 进一步将评测扩展到更贴近真实互联网的复杂环境，突出端到端评测中“检索、阅读、规划、执行、纠错”的闭环能力^[55]。

与上述“任务级”评测相配套，界面元素的精确定位（例如“点击哪个按钮”）也逐渐成为能力瓶颈之一。SeeClick 等工作将 GUI 控制进一步聚焦到细粒

度点击与定位问题，提示模型需要更强的视觉指向 (grounding) 能力以及更严格的坐标/区域监督^[13]。

在更通用的桌面操作系统场景中，OSWorld 将评测进一步扩展到 Ubuntu/Windows/macOS 等真实计算机环境，提供面向开放式任务的可复现容器化沙箱、跨应用 workflows 以及基于代码执行的可重复评测脚本，构建了 369 个覆盖真实 Web/桌面应用与文件 I/O 的任务，并揭示了即使顶尖模型在 GUI Grounding 与操作性知识上仍与人类存在显著差距（人类 72.36% vs. 最佳模型 12.24%）^[6]。围绕该评测体系，近期工作进一步将**可验证任务合成**与大规模异步沙箱回放相结合，把 CUA 能力提升从“被动模仿静态数据”推进到“基于合成经验的进化学习”：以 EvoCUA 为代表，其通过可执行验证器自动生成任务-轨迹-奖励，并采用拒绝采样微调与步级偏好优化迭代提升 agent，在 OSWorld 上达到了开源 SOTA 56.7% 的成功率^[34]。这类工作进一步印证了“数据侧可验证合成 + 闭环评测式质控”思路在真实 Computer Use Agent 场景下的必要性，也为本文第5章 Auto-Evol 框架向 GUI CUA 领域的实例化提供了直接的方法学参照。

2.3 世界知识与多模态知识推理

世界知识 (World Knowledge) 能力指模型对事实、概念与关系网络的掌握，以及在视觉证据与知识之间建立可验证链接并完成多步推理的能力。对于视觉语言模型而言，世界知识增强的难点通常不在于“语言侧是否存储过知识”，而在于“视觉侧是否能稳定锚定实体实例”，以及“推理链路是否可控、可迁移”。

2.3.1 知识型视觉问答基准

世界知识能力在多模态研究中常通过“知识型视觉问答 (Knowledge-based VQA)”体现：问题往往无法仅从图像像素直接回答，必须结合外部常识、百科或领域知识。OK-VQA 提出了需要外部知识的 VQA 基准，推动研究从“看图问答”走向“看图 + 用知识回答”^[16]；A-OKVQA 进一步强化了对常识与知识组合推理的要求，使得模型需要在候选知识、视觉证据与推理链之间建立更稳定的对应关系^[27]。随着开放世界问题增多，WebQA 等工作将多模态问答扩展到“跨模态多跳检索与推理”，强调证据可追溯性与多源证据融合^[29]；InfoSeek 等基准则进一步强调“信息检索式”的问答设定，要求模型能够主动检索并在证据约束下回答，从而更适合评估事实性与幻觉控制能力^[28]。

2.3.2 思维链推理与工具增强

推理方法与对齐策略对世界知识问答质量至关重要。链式思维提示 (Chain-of-Thought, CoT) 表明显式推理过程可以显著提升 LLM 在复杂任务上的表现^[33]。

围绕 CoT，后续研究进一步从推理路径的可靠性与推理过程的可控性两方面增强推理能力：Self-Consistency 通过对同一问题采样多条推理链并进行一致性聚合，缓解单一路径的偶然错误^[56]；Tree-of-Thoughts 则将“思维”视为可搜索的中间状态，引入分支探索与回溯以提升需要规划/搜索任务的解题能力^[57]。

更进一步，世界知识问题往往要求模型在外部证据约束下推理，单纯生成推理链容易产生幻觉或证据缺失。ReAct 提出将“推理轨迹”与“行动（如检索/查询工具）”交错生成，通过与外部知识源交互来降低幻觉与错误传播^[31]。在多模态场景中，相关思想也被扩展为“多模态推理链”：Multimodal-CoT 通过分阶段生成多模态依据与答案推断，提升知识型 VQA 等任务的稳定性^[17]；MM-REACT 进一步将语言模型与多种视觉专家工具结合，实现“看图 → 调用专家 → 推理 → 行动”的系统范式^[58]；ViperGPT 则通过生成并执行 Python 程序来组合视觉子模块，提高可解释性与可组合推理能力^[59]。这些工作共同表明：面向世界知识的多模态推理需要“实体锚定 → 证据检索/调用 → 可验证推理”的闭环，而 CoT 类方法为构造可迁移、可审计的推理监督提供了重要工具。

2.3.3 指令微调与人类反馈对齐

为了让模型更好地遵循人类指令并输出高质量的回答，指令微调 (Instruction Tuning) 成为了关键技术。InstructGPT 通过基于人类反馈的强化学习 (RLHF) 显著提升了模型遵循指令的能力^[60]。

进一步地，为了解决高质量指令数据稀缺的问题，Self-Instruct 提出了通过模型自举生成指令数据以实现对齐的方法^[11]。Orca 等工作则进一步探索从强教师模型（如 GPT-4）的“解释轨迹 (Explanation Traces)”中进行渐进式学习，通过模仿教师模型的推理过程来提升学生模型的复杂推理能力^[12]。这些研究共同指出：当任务需要多步推断与事实一致性时，仅监督最终答案可能诱发“短路映射”或幻觉，过程性监督与可验证约束更利于能力迁移。

2.3.4 事实性评测与检索增强生成

衡量与改进模型事实性也是世界知识增强的重要组成部分。SimpleQA 聚焦短回答场景下的事实性评测，为分析模型在事实正确性上的薄弱点提供了参考^[32]。在方法层面，检索增强生成 (Retrieval-Augmented Generation, RAG) 等工作通过在生成前检索外部文档并在生成时融合证据，提供了一条提升事实性与可追溯性的通用路径^[30]。在多模态场景中，世界知识能力往往体现为“先识别再调用知识”的链路是否稳定、答案是否唯一可核验。本文第4章即在这一思路下构造 RecQA/KnowQA/FinalQA 分解，并通过引入带 CoT 的 FinalQA 提升可迁移推理能力。

2.4 多模态数据合成与质量控制

随着 MLLM 参数规模的不断增长，高质量数据的稀缺性逐渐成为限制模型性能提升的瓶颈。如何规模化构造高质量、强对齐且具备推理密度的数据成为当前研究的关键问题。现有工作主要围绕三个方向展开：提升 caption 质量与对齐度、指令数据的进化与扩展、以及利用生成模型进行反向数据工程。

2.4.1 高质量 Caption 与图文对齐数据

传统的图文数据集往往存在描述简短、信息遗漏等问题。ShareGPT4V 通过利用 GPT-4V 生成详尽的图像描述 (Dense Caption)，证明了“更好的描述”可以显著改善视觉-语言对齐效果，进而提升下游任务的性能^[18]。这类工作的核心启示在于：Caption 不仅是训练目标，更是连接视觉信号与语言语义的桥梁。通过将图像转化为可复用、可验证的文本证据，可以有效降低模态间的语义鸿沟。

从更宏观的角度看，数据规模与覆盖度同样决定了对齐的上限。LAION-5B 等工作构建了超大规模开源图文对数据集，为训练与评测下一代图文对齐模型提供了基础设施^[8]；COYO-700M 等数据集进一步展示了“更大规模弱监督数据”在训练可迁移视觉-语言表征上的价值^[9]。与此同时，如何在规模扩展下控制噪声与偏差，也成为数据工程与模型训练共同面对的问题。

2.4.2 指令进化与代理式合成

在纯语言领域，Self-Instruct 提出了通过模型自举 (Bootstrapping) 生成指令数据以实现对齐的方法，极大地降低了人工标注成本^[11]。这一思想被迅速引入多模态领域。MMEvol 将 Evol-Instruct 思想拓展到多模态场景，提出细粒度感知进化 (Fine-grained Perception Evolution)、认知推理进化 (Cognitive Reasoning Evolution) 与交互进化 (Interaction Evolution) 三类策略，以视觉约束为前提同时扩展指令的难度、覆盖与交互形式，从 SEED-163K 种子数据进化得到 MMEvol-480K 训练集，避免了“仅做文本复杂化而脱离图像证据”的常见陷阱^[19]。

更进一步，AgentInstruct 引入了代理流 (Agentic Flow) 的概念，将数据合成过程组织为多步骤的代理协作流程，通过模拟用户与系统的交互来生成更具逻辑性和连贯性的数据^[61]。在结构化推理任务上，Synthesize Step-by-Step 通过结合工具调用、模板填充与 LLM 生成，构建了包含推理步骤的图表问答数据，为“可执行/可验证”的数据构造提供了范例^[62]。这些方法共同体现了数据构造从“单轮生成”向“流程化、结构化生成”的演进趋势。

2.4.3 合成数据的幻觉风险与质控机制

当数据构造从“人工标注”逐步转向“模型生成 (Caption/指令/图像/轨迹)”时，合成数据不可避免地引入幻觉 (Hallucination) 与失真 (Distortion)：模型可能在描述中虚构不存在的对象或属性、在指令中生成与界面不匹配的操作目标、或在多步轨迹中产生不可执行的状态转移。这些噪声一旦作为监督信号回灌训练，往往会以“错误对齐”的方式固化到模型中，并在规模扩张时被放大。

一类典型风险来自 Caption 与对象一致性：自动 Caption 器可能倾向于补全“常见但未出现”的对象，从而造成对象幻觉。POPE 提出以投票式查询 (Polling-based Query) 更稳定地评测大视觉语言模型的对象幻觉问题，为合成文本的质量诊断提供了工具^[15]。在工程上，类似 CLIPScore 这类参考无关的图文一致性指标也常用于大规模过滤与重采样，以提升合成监督的可靠性^[10]。

另一类风险来自指令-元素对齐与可执行性：在 GUI/交互数据合成中，若仅依赖模型“看图生成指令”，很容易产生目标元素不存在、边界框偏移或隐式指令理解失败等问题。UI-E2I-Synth 通过引入大规模指令合成管道并聚焦元素比例失真、元素类型不平衡与隐式指令等难点，同时构建 UI-I2E-Bench 进行细粒度诊断，展示了“合成 → 评测 → 再合成”的质控闭环对降低幻觉的重要性^[25]。

此外，合成数据还存在递归训练的分布塌缩风险：当模型反复使用自身或同类模型生成的数据进行训练时，长尾分布可能逐步消失并导致能力不可逆退化 (Model Collapse)^[63]。因此，当前多模态数据工程普遍强调：在扩大合成规模的同时，必须维持真实数据锚点、引入结构化验证器/可执行回放、并以多维指标持续监控噪声与偏差。本文后续提出的多源融合、结构化标注与质控迭代，也正是在这一“幻觉可诊断、质量可闭环”的原则下展开。

2.4.4 文本到图像的反向数据工程

除了基于现有图像生成文本 (Image-to-Text) 的正向数据流外，利用生成模型进行“文本到图像 (Text-to-Image)”的反向数据工程也日益受到关注。SynthVLM 系统研究了合成图文数据集的构建策略，通过 Caption 清洗、扩散模型生成与自动质量筛选等环节，构建了大规模的高质量图文对^[20]。得益于 SDXL 等高质量扩散模型的发展，生成的图像在分辨率和语义一致性上已达到较高水平^[51]。

对于本文所研究的“多模态数据合成框架”而言，正向与反向两类数据流的结合，使得系统既能覆盖真实世界的长尾分布，又能在特定场景下进行可控的数据补齐，从而实现数据质量与规模的双重提升。

2.5 已有工作进展与本文工作的差异化

2.5.1 已有工作进展归纳

综合本章前述四个方向的回顾，可以观察到当前多模态研究在四条线上均已取得显著进展。第一，视觉-语言模型与多模态大模型已经从早期的对比式表征对齐演进到以大语言模型为核心的生成式架构，并在指令跟随、长上下文与多任务覆盖上不断延展，模型层面的能力上限主要由训练数据的质量与结构决定，而非架构差异。第二，面向 GUI 的视觉理解与智能体研究已经形成从静态截图理解、UI 数据集与基准、到跨平台动作模型与开放任务评测的完整链路，并在 OSWorld、WebArena 等真实环境基准上揭示了模型与人类之间仍存在的显著差距。第三，世界知识相关研究在知识型视觉问答基准、思维链与工具增强、指令微调与对齐、事实性评测与检索增强等方面提供了较为成熟的方法栈，整体思路从“看图问答”推进到“识别-调用知识-可验证推理”的链路化处理。第四，多模态数据合成已经从单环节优化（Caption 增强、指令进化、反向数据工程）走向多模块协作，并开始关注合成数据的幻觉与质控问题。

尽管已有工作涵盖了从模型架构、任务评测到数据生产的多个层面，仍然存在三个共性局限：其一，已有数据合成研究多聚焦在某一环节的局部改进（如 Dense Caption、指令进化、文生图），缺乏面向能力维度的统一框架，难以在不同任务域之间迁移与复用；其二，多数合成方法在“数据校验”上仍以 LLM-as-a-Judge 为主，过程性约束与可执行验证较弱，导致合成噪声易在规模扩张时被放大；其三，已有研究在感知任务（如 GUI Grounding）与推理任务（如知识 VQA）之间通常各自为政，缺少能够同时容纳两类极端需求并支持跨任务复用的合成方法学。

2.5.2 本文相对已有工作的差异化贡献

针对上述共性局限，本文在前述工作基础上提出三点差异化贡献，对应论文后续三个核心章节的实证与抽象。

第一，在感知端面向 GUI 任务，本文在已有 Rico、MobileViews、OS-Atlas、SeeClick 等数据与方法基础上，进一步构建以 bbox、OCR、控件关系图谱与状态向量为核心的多源结构化数据合成 Pipeline，并配套 AnyRes 高分辨率感知与双阶段混合微调策略，在主流应用真实分布评测中获得显著提升（详见第3章）。相对已有 GUI 工作，本文更强调“可执行、可校验”的像素级监督与跨数据源融合的质控闭环。

第二，在推理端面向世界知识任务，本文在 OK-VQA、A-OKVQA、InfoSeek 等基准与 CoT、Multimodal-CoT、ReAct、RAG 等推理方法之上，构建覆盖 7 大

类 40 子类的知识类别框架与“词条 → 图片 → caption → 相关性过滤 → RecQA/ KnowQA/FinalQA”的端到端数据 Pipeline，并在 FinalQA 中显式引入带 CoT 的过程监督（详见第4章）。相对已有工作，本文不仅给出更细粒度的类别框架，还把“识别-知识-推理”三段链路直接落到可学习、可校验的训练信号上。

第三，在前两端实践之上，本文进一步抽象提出 Auto-Evol 多模态数据合成框架。相比 ShareGPT4V、MMEvol、SynthVLM、Synthesize Step-by-Step、AgentInstruct 等分别针对 caption 密度、指令进化、反向生图与分步推理数据等单一关键环节进行优化的合成方法，Auto-Evol 强调三个层面的差异化：一是以“感知/理解/推理”三能力为统一坐标系组织数据生成与监督，使得不同任务的数据合成可在同一框架下复用；二是把数据校验明确为评测式验证并引入可执行验证器，将合成数据的“幻觉可诊断、质量可闭环”原则前置到数据侧；三是借助 OSWorld/EvoCUA 等评测体系将框架实例化到 GUI CUA 综合中段场景，通过端到端 SFT 实验给出可量化的能力增益证据（详见第5章）。三者共同表明，本文相对已有工作的进步并不在于单一环节的精细优化，而在于将“可控、可迭代、可验证”的合成原则上升为可跨任务迁移的统一框架。

第 3 章 面向用户图形界面的视觉语言 模型能力提升

如第1章所述，本文沿**数据能力光谱**三个代表性位置（感知端 / 推理端 / 综合中段）展开“两端实证 → 共通抽象 → 综合中段端到端验证”的研究路径。本章是该路径的第一站——**感知端实证**：以图形用户界面（Graphical User Interface, GUI）任务为载体，回答“在控件密集、文字细小、状态易变的场景下，如何把数据做到精细到像素、对齐到字段、绑定到状态”。该问题的答卷将在后续第4章（推理端世界知识任务）的另一端实证形成对照，并共同为第5章 Auto-Evol 统一框架的抽象提供模块级原型。

3.1 任务定义与核心挑战

随着移动端与桌面端用户界面智能体（UI Agent）从“演示原型”走向“真实可用”，能否在屏幕上稳定地“看懂控件、点对位置”成为决定其落地价值的前置能力。本节先给出本章关注的两项基础能力定义，再从这两项能力在真实 GUI 场景中暴露出的稳定性问题归纳出三大核心挑战，并据此明确本章的研究目标与方法路线。

3.1.1 基础能力：Referring 与 Grounding

本章关注 UI Agent 感知-决策闭环中两项最基础的视觉-语言能力。**指代识别（Referring）**要求模型在给定屏幕区域的边界框（Bounding Box, bbox）后，输出该区域控件的功能、文本或属性描述（例如对“在 bbox [10,10,50,50] 区域的控件是什么？”输出“这是搜索按钮”），强调对界面的语义理解；**视觉定位（Grounding）**则要求模型在给定自然语言指令时，在屏幕截图中定位对应控件并输出其 bbox（例如对“登陆按钮在哪里？”输出“bbox [100,200,300,400]”），强调对界面的精确定位。两者在形式上互逆，共同构成 UI Agent “看懂屏幕-指向目标”的能力底座，也是本章后续数据合成与训练优化的直接监督目标。

3.1.2 三大核心挑战

尽管通用 MLLM 已具备一定视觉理解能力，但在 GUI 垂直领域同时稳定输出 Referring 与 Grounding 仍存在三大核心挑战。挑战一是细粒度定位偏差：移动

端与桌面端控件多以小面积图标、密集排布的列表项与紧贴布局的开关/按钮形式出现,模型需要在像素级输出稳定的坐标,但小目标的 bbox 容易出现“整体方向对、像素级偏移大”的情况,导致 IoU 严重下降。挑战二是图片信息损失严重:若直接将原图缩放到视觉编码器的固定正方形输入(如 224×224 或 336×336),细小图标与字体被压缩后趋于同质化,进而表现为 OCR 失效、视语对齐变弱与定位偏差扩大,这一损失在中文移动端竖屏场景尤为显著。挑战三是视觉与语言难以对齐:传统检测模型缺乏语义理解能力,而通用视觉语言模型在“标签-输入框”、“值-控件”、“关闭按钮-广告容器”等跨控件关系上往往绑定不稳,呈现“看似可点但不可点”、“识别正确但点错位置”等结构性误差。这三类挑战共同决定了:仅靠通用 MLLM 的零样本能力不足以覆盖真实 GUI 场景,必须在数据、架构与训练三个层面同时引入针对性的设计。

3.1.3 研究目标与本章路线

为应对上述挑战,本章提出一套以多源数据工程为核心、结合双阶段混合微调 (Dual-Stage Mixed Tuning, DMT) 与高分辨率架构优化的系统方案,目标是在移动端 GUI 最流行前 200 应用的真实使用场景测试数据中实现 Referring 准确率 $\geq 90\%$ 、单控件 Grounding 准确率 $\geq 90\%$ 。为帮助读者快速把握“挑战 $\rightarrow$ 方法 $\rightarrow$ 量化验证”的完整对应关系,表 3-1 给出本章核心问题、本文方法(创新点)与对应实验结果的总览;后续将按“数据工程 $\rightarrow$ 架构与训练 $\rightarrow$ 实验验证”的顺序逐一展开。

3.2 本章核心方法概览

针对前述 GUI 三大挑战(细粒度定位偏差、图片信息损失、视语对齐松散)与配套的能力冲突/数据冗余等工程难点,本文从“数据+架构+训练”三个维度共提出 6 项关键技术,统一构成第 3 章的核心创新点。这 6 项技术在前述表 3-1 已与挑战与实验形成一一对应,本节进一步用一段文字把它们浓缩为可被快速检索的“方法卡片”:

- **C1 · 三类训练任务联合监督** (数据侧): 同时构造 Task Grounding (指令 $\rightarrow$ bbox)、State Transition (截图对 $\rightarrow$ 状态变化判断) 与 Referring 双向 QA (bbox $\leftrightarrow$ 语义描述) 三类训练任务,打牢“语义-定位-状态”三条能力链路,且 Referring 与 Grounding 在形式上互逆,可相互强化视觉-语言对齐稳定性。
- **C2 · 23 类细粒度控件分类学** (标注规范): 剔除 CARD_VIEW / LIST_ITEM 等强布局相关类别,遵循“原子粒度优先”原则,构建覆盖移动端原子交

表 3-1 第3章 GUI 挑战、本文核心方法（创新点 C1–C6）与对应实验验证总览。“二级近重复去重”为质控阶段的辅助手段，不计入 6 项核心创新；C1（三类训练任务联合监督）作为数据侧基础设计贯穿三大挑战，其整体收益在表3-2的多源数据消融中体现。

GUI 挑战	本文方法（核心创新）	量化验证
(1) 细粒度定位偏差 小控件坐标不稳定	C2 · 23 类细粒度控件分类学（剔除布局类，原子粒度优先）+ C5 中的 1000 级坐标量化与文本化坐标输出	表3-3 IoU $\geq$ 0.5 F1=0.846
(2) 图片信息损失 缩放后细节丢失	C5 · AnyRes 全局缩放 + 自适应网格切分（Patch 位置编码 + 特征融合）	表3-3 含小控件（图标、页面指示器）评测
(3) 视语对齐松散 “标签-控件”绑定不稳	C3 · 有向关系图谱 (R_{ext} / R_{val} / R_{func}) + C4 · 三元状态向量 (Activated/Interactable/Filled) + OCR 增强	表3-4 Referring 加权 F1=0.905
跨能力链路监督不足 (视语-几何-状态三链路同时学习)	C1 · 三类训练任务联合监督 (Task Grounding / State Transition / Referring 双向 QA)	表3-2 多源融合下整体提升
跨任务能力冲突 与灾难性遗忘	C6 · DMT 双阶段混合微调 (阶段 1: 100% GUI 注入; 阶段 2: 80–85% 通用 + 15–20% GUI 回放)	表3-2 多源数据融合一致提升
数据冗余 与同质化 (质控辅助)	二级近重复去重 (一级 hash 精确 + 二级 visual embedding $\oplus$ 页面指纹双阈值)	图3-1 质控阶段闭环

互、复合容器与动态调整三大类的 23 类核心控件体系，显著降低类别歧义。

- **C3·控件有向关系图谱** (标注规范): 在传统“类别 + 坐标”基础上额外标注三类有向关系—— R_{ext} (标签 $\rightarrow$ 控件)、 R_{val} (值 $\rightarrow$ 控件) 与 R_{func} (功能依赖)，显式建模“用户名输入框”等跨控件语义绑定，缓解视语对齐松散。
- **C4·三元交互状态向量** (标注规范): 为每个控件附加 Activated / Interactable / Filled 三元状态信号，区分“看似可点”与“真可点”、“已填写”与“待输入”等关键状态，避免误监督。
- **C5·AnyRes 与 1000 级坐标量化** (架构): 视觉侧采用 AnyRes 动态分辨率机制 (全局缩放 + 自适应网格切分 + Patch 位置编码 + 特征融合)，同时给出全局视野与局部细节；语言侧把 bbox 坐标统一离散化到 0–999 整数区间，配合 $\langle |box_start| \rangle / \langle |box_end| \rangle$ 等特殊 Token 约束输出结构，实现跨分辨率泛化与可解析坐标生成的统一。
- **C6·DMT 双阶段混合微调** (训练): 阶段一用 100% GUI 数据完成领域知识注入；阶段二引入 80–85% 通用多模态对话数据，并按 15–20% 比例回放阶段一的高质量 GUI 样本，同时缓解能力冲突与灾难性遗忘，避免单阶段微调下“GUI 强但通用退化”或“通用强但 GUI 遗忘”的两难。

上述 6 项技术之间并非孤立——C1–C4 共同构成数据侧的“高密度结构化监督” (多源数据 + 三件套标注规范 + 三类训练任务)，C5 解决了模型如何“看清”并“输出”高密度监督，C6 解决了模型如何在不丢失通用能力的前提下“吸收”这些 GUI 监督。这一“数据 $\rightarrow$ 架构 $\rightarrow$ 训练”的三段式设计，是本章方法体系的统一脉络，亦是后续第5章 Auto-Evol 框架将其归并到统一的“结构化初始化 + 任务原子化 + 多维校验 + 闭环迭代”骨架时的实证起点。

3.3 数据工程：多源融合与高质量构建

数据是 GUI 理解能力提升的基石。本节围绕“多源融合”与“高质量构建”两条主线，构建开源清洗数据、闭源精标数据与合成数据相互补位的训练语料体系，以保证数据质量可控、可迭代。

3.3.1 GUI 数据构造流程

GUI 领域的 Referring 与 Grounding 能力提升，本质依赖于“理解语义且精准定位”的数据监督：模型既要学会控件的语义功能 (登录/搜索/关闭等)，又要学

会在高分辨率、密集布局中输出像素级稳定的定位结果。相比自然图像，GUI 场景存在小目标密集、文字依赖强与交互状态多变等特点，其中“文字依赖”指的是：移动端控件种类多样、外观相似但功能多变，大量关键语义（如“登录/下一步/同意/关闭”以及输入框的字段含义与提示信息）主要通过界面文字表达，必须借助截图中的文本信息（OCR）才能准确判断控件身份与动作目标。使得简单的图文对或粗粒度检测标注难以覆盖真实需求。因此，为了切实提升模型的 GUI 场景下的能力，本节提出了一种可以处理多种开源数据，同时通过重写、人工精标的方法来构建高质量数据的数据构造流程。

整体流程可概括为“收集多种源数据 → 结构化初始化 → 混合标注与属性补全 → 清洗与结构化聚合 → 任务/QA 数据合成与过滤 → 质控与迭代”。图3-1给出了该流程的可视化全景：从多源输入（开源/闭源/合成）经过四个阶段（结构化初始化 → 人机协同混合标注 → 三类 QA 合成 → 质控 + 二级去重）后，输出可用于 AnyRes + 文本化坐标 + DMT 训练策略的高质量训练语料，且质控阶段的失败样本会回流到混合标注阶段继续优化，形成闭环。

下面分模块说明其必要性。收集多种源数据是流程的起点，决定了后续数据分布的上限：为覆盖真实分布与长尾场景，数据来源同时包含开源 GUI 样本（提供多样布局先验）、闭源真实 App 截图（补齐中文与主流应用生态），并视需要引入合成/重写样本以补足稀缺交互形态与困难指令表达。本文实践中，开源侧主要收集并清洗重构了 Rico、MobileViews、OS-Atlas 等数据，闭源侧则面向主流 App 采集真实操作截图并迭代构建高质量自有数据集。结构化初始化承担“图像 → 中间表示”的转化任务，将不同来源样本统一为可计算、可追溯的结构化记录（截图、分辨率、视图层级、候选控件集合等），并规范坐标表示与字段定义；为保证不同分辨率设备与不同数据源之间的可混合训练性，本文进一步设计了统一的动作空间，并将所有 bbox 坐标做一致的离散化归一（即 1000 级量化，将像素坐标映射到 0-999 的整数区间），使“点击/框选”等动作目标能够以统一格式被标注、生成与解析。混合标注与属性补全围绕控件级 bbox 与文字内容进行高质量标注，并补充可交互性与状态等属性，通常采用“检测 + OCR + 属性预测”的自动化预标注，并由人工校验与补充兜底；该步骤同时回应 GUI 三大难点：通过紧致 bbox 缓解小控件定位偏差，通过 OCR 字段解决文字依赖，通过状态/可交互标签避免“看似可点但不可点”的误监督。任务/QA 数据合成与过滤在结构化标注与控件集合基础上生成面向训练的指令/问答数据，本文据此构造 Task Grounding（“指令 + 截图 → 目标 bbox”）、State Transition（“截图对 → 状态变化判断”）与 Referring 双向 QA（“bbox+ 截图 → 语义描述”）三类训练任务，将能力同时拆解到感知、理解与状态三条链路上；并通过规则过滤与相似度去重降低噪声与冗余。质控与迭代是闭环的“收尾与起点”：对样本进行一致




图 3-1 GUI 数据合成 Pipeline 全景图：4 阶段 + 失败回流闭环。上层为多源输入（开源/闭源/合成）；中部依次为结构化初始化（1000 级坐标量化）、人机协同混合标注（自动预标注 + 23 类分类学/关系图谱/状态向量三件套标注规范）、三类 QA 合成（Task Grounding / State Transition / Referring 双向）、质控与二级去重；下层为训练阶段对应的 AnyRes + 文本化坐标 + DMT 策略。

性与正确性检查（bbox 合法性、OCR 与文本一致性、指令与目标控件匹配、关系图完整性），并将失败样本回收为后续补标/重写/再采集的候选，从而保证数据分布稳定、降低噪声与抑制幻觉。

需要强调的是，上述流程虽然并非后续章节提出的多模态数据合成框架，而是从 GUI 任务需求出发的一种可行数据工程路径：它首先明确了 GUI 训练数据必须同时覆盖语义与图形定位，并以“结构化初始化-精细标注-任务化构造-质控迭代”为核心步骤，为后续提出更通用的多模态数据合成框架奠定基础。

3.3.2 开源数据清洗与重构

开源数据在规模与多样性上具备优势，但往往存在噪声、布局失真与语义标签不一致的问题。以 RICO 为代表的 GUI 数据集^[21]包含大量移动端界面及其视图层级（View Hierarchy），然而原始数据中存在不可见节点、错误标注、层级断裂等现象，直接用于训练会导致模型学习到错误的几何与语义先验。本文采用 CLAY（Clean Layout for Android UI）思路对 RICO 进行清洗与增强^[23]，主要包含三方面工作：一是噪声过滤与层级修复，剔除包含“INVALID”标签、尺寸为 0、透明不可见等节点，并修复视图树结构，确保层级关系可用于后续关系建模与样本构造；二是语义标签映射，将原始 Android View 类名映射为更具语义的通用组件类别，以减少类别碎片化带来的学习难度，例如将 `android.widget.EditText` 及其子类统一映射为 `TEXT_INPUT`，将 `FloatingActionButton` 映射为 `BUTTON`；三是任务 Prompt 构造，在清洗后的结构化数据上生成标准化监督样本——Grounding 任务以自然语言指令（如“点击右上角的搜索图标”）与页面截图为输入、输出归一化 bbox，Referring 任务以 bbox 与页面截图为输入、输出组件类别、功能与可见文本（可结合 OCR 字段）。

通过上述处理，开源数据为模型提供了覆盖广的 GUI 布局先验与基础交互语义，但在中文场景、复杂交互与状态理解上仍存在缺口，需要闭源数据与合成数据补齐。除 RICO 外，本文在开源侧还引入了 MobileViews^[22]与 OS-Atlas^[5]两类 GUI 数据以补齐交互覆盖与定位监督。MobileViews 是面向移动端智能体与 UI 分析的大规模数据集，其 MobileViews-600K 版本包含从 Google Play Store 上两万余应用采集的 60 万级“屏幕截图-视图层次结构（VH）”配对数据；最新版本基于 DroidBot 并针对大规模采集进行了优化^[52]，在保持与 DroidBot 输出结构一致的同时能够捕获更全面的交互细节，本文利用其控件类型与组成信息（包括 bbox 与控件内文字）构造训练样本，将控件文字作为 OCR 监督与 Referring 依据，并将 VH 中的层级与控件类型作为语义先验，增强模型对复杂页面结构的泛化能力。OS-Atlas 主要提供 GUI Grounding 数据集^[5]，其中目标元素位置存储在 bbox 字段，采用 `[left, top, right, bottom]` 的归一化小数表示（每个值均为 `[0, 1]`）

范围内相对图像宽高的比例)；在任务构造时，本文将其与其它数据源统一到一致的坐标表示与字段规范（并保持 bbox 的几何语义一致），用于补强“指令 → 目标控件位置”的 Grounding 监督，尤其覆盖长尾指令表述与跨应用布局差异。

3.3.3 闭源数据构建

针对开源数据在中文语境、主流 App 生态与复杂交互状态覆盖上的不足，本文构建闭源高质量 GUI 数据，并按迭代版本记为 v1 与 v2：其中 v1 用于早期验证与规范冷启动，重点覆盖文本输入、开关、弹窗等高频交互组件；v2 在 v1 基础上进行二次校验，剔除定义不清的控件并加入负样本（不可点击区域/误导性区域），以提升 Grounding 的判别能力。闭源数据构建强调“可训练”与“可评测”的一致性：既提供控件级几何定位监督，也提供可解释的语义与状态监督，并进一步产出可用于指令学习的 UI 意图问答数据。

第一阶段：数据标注（混合标注模式） 该阶段从原始截图开始（可选携带页面 XML/VH 等元数据），采用“自动化预标注 + 人工校验补充 + 纯人工兜底”的混合模式以兼顾效率与准确性。具体而言，先由轻量检测模型（如 YOLO^[64]）自动检测图标、按钮、输入框等控件并输出 bbox；接着对候选框区域使用 PaddleOCR 提取控件文字（如“登录”“取消”等）形成文字与位置的对齐监督^[14]；随后利用已训练的多模态模型（如 Qwen2-VL）对候选控件进行属性补全，包括控件细分类别、可交互性以及选中/开启等状态^[3]。最后由标注人员对预标注结果进行校验与修正，并补充模型遗漏的控件；对于复杂样本走纯人工标注分支，最终合并得到统一标注结果，确保每个关键控件的 bbox（位置）、类别（类型）与属性（文字/状态/可用性等）准确一致。OCR 增强是闭源数据的重要补强环节：为降低通用 OCR 在艺术字体与复杂背景下的误识别与“幻觉”，本文引入更高精度的文本抽取与校验流程，生成用于训练的高质量中文文本标注，从而让模型在 Referring 任务中能够稳定对齐“控件外观-文字内容-交互语义”三者。

第二阶段：数据清洗与结构化 该阶段对标注结果进行质控与格式转换，生成训练友好的结构化数据表示。质控环节首先进行质量校验，检查 bbox 合法性、OCR 文本异常（如过长/乱码）、属性冲突（例如“不可交互但标为可点击”）以及控件间的关联关系是否合理；随后进行数据提纯与聚合，生成包含控件类型、属性、bbox 的纯净样本，并以图片为单位聚合为控件列表（每张截图关联一个包含其所有 UI 元素的集合）；最后通过格式转换将结构化控件集合转换为多种下游格式，以支持指代理解（ref）、定位落地（grd）、列表/容器理解（list）等任务的数据构造与训练。

第三阶段：QA 数据合成与过滤 该阶段是将结构化控件信息转化为可监督、可解析的训练样本的核心步骤。本文生成的 QA 主要对应三类任务：Task Grounding QA 以“自然语言指令 + 截图”为输入、输出目标控件的 bbox（与前述 grounding 监督一致）；State Transition QA 以两张连续操作截图为输入、围绕界面状态变化提出问题并给出可验证答案（例如“哪个区域从不可交互变为可交互/哪个开关状态发生变化/页面是否跳转至新状态”等）；Referring QA（反向 QA）以“bbox+截图”为输入、输出目标控件的类别/功能/文本等语义描述，从而与 grounding 形成形式上的双向对应（指令 $\leftrightarrow$ 目标控件描述），增强视觉-语言对齐的稳定性。具体生成时，将聚合好的控件信息与精心设计的系统提示（sys prompt）及少样例（few-shot examples）结合，调用强多模态模型（如 GPT-4o/Qwen2-VL）进行半结构化生成^[1,3]，并对输出格式（如 bbox 整数坐标、答案可核验字段）施加约束，保证样本可直接用于训练与自动化质检。

为保证质量与覆盖，进一步执行数据过滤与去重。噪声过滤基于规则（如问题过短、答案无意义、指令与目标控件不匹配等）剔除低质量样本。近重复去重则针对 GUI 数据中“同一页面多次采集/相似布局跨应用复现/连续帧高度相似”等现象——这些现象会让样本在训练中被重复计数，既浪费 token 预算也会放大高频模式、挤压长尾覆盖。为此本文采用分层近重复去重策略：

- 一级粗去重（精确重复）：对截图（以及 State Transition 中的“截图对”）计算文件哈希或感知哈希，直接移除完全相同或几乎不变的重复帧，先消除采集与导出造成的显式重复。
- 二级近重复（语义/布局相似）：为每张截图提取全局视觉表征向量（image embedding，即将整张界面输入预训练视觉编码器，取其池化后的 d 维特征并做 L_2 归一化得到 $\mathbf{e} \in \mathbb{R}^d$ ），并结合结构化信息构造轻量“页面指纹”（OCR 文本集合、控件类型直方图与归一化 bbox 布局摘要）；候选近邻检索同时考虑视觉相似度与页面指纹相似度，视觉相似度由余弦相似度 $s(\mathbf{e}_i, \mathbf{e}_j) = \mathbf{e}_i^T \mathbf{e}_j / (\|\mathbf{e}_i\| \|\mathbf{e}_j\|)$ 计算（向量已归一化时等价于内积），页面指纹相似度由文本重叠率/直方图距离/布局摘要距离等组成；只有当两者均高于阈值时才判定为近重复并合并，以避免“视觉相似但语义不同”（如不同商品/不同表单字段）的误删。
- 保留策略（避免过度裁剪）：对每个近重复簇保留代表样本，并优先保留覆盖不同指令表述/不同目标控件/不同状态变化类型的 QA；对于 State Transition 任务以“截图对”为单位去重，避免仅按单帧去重导致关键信息（变化前/变化后）被破坏。

除上述三阶段流程外,针对闭源数据本文还建立了一套标准化的平台屏幕控件标注规范。该规范不仅关注视觉边界 (bbox), 还显式引入控件分类学、控件关系图谱与状态向量, 从而为 Referring 提供可解释的语义监督信号, 并为 Grounding 提供“可交互目标”的判别依据。

细粒度控件分类学 (Taxonomy) 首先构建了覆盖移动端原子级交互单元与容器级逻辑单元的 23 类核心控件体系, 遵循“原子粒度优先”原则, 以减少布局强相关类别造成的歧义。整体可分为三大类: **原子交互类 (Atomic Interaction)** 涵盖 BUTTON、ICON、TEXT、IMAGE 以及输入与开关类 (如 TEXT_INPUT、SWITCH) 等原子化交互元素; **复合容器类 (Composite Containers)** 涵盖 NAVIGATION_BAR、TAB_BAR、CONTAINER、POPUP、ADVERTISEMENT、NOTIFICATION 等承担布局与逻辑分组职能的容器; **动态调整类** 涵盖 SLIDER、PROGRESS_BAR 及其区域类控件等需要随用户操作而连续变化的控件。在该规范中, 剔除了 CARD_VIEW、LIST_ITEM 等布局强相关类别, 转而采用“原子粒度优先”的原则, 以减少模棱两可的布局标注, 并促使模型更关注交互本质。

语义关系建模 (Directed Relationship Graph) 传统检测仅预测类别与坐标, 缺乏对控件间逻辑的理解。为此, 该规范在标注中显式构建控件间的有向关系图 (Directed Relationship Graph), 该信息对 Referring 尤为关键。本文定义三类有向关系: **标签-控件绑定 (Label-to-Control)** 记为 $R_{ext} = (T_{label} \rightarrow C_{target})$, 例如输入框左侧的“用户名”文本被标记为外部注释并指向对应的 TEXT_INPUT, 使模型能够更稳定地理解“点击输入用户名的位置”这类指令; **值-控件绑定 (Value-to-Control)** 记为 $R_{val} = (T_{value} \rightarrow C_{target})$, 例如输入框中已填写的“张三”、下拉框当前显示的“北京市”被标记为当前值并指向父控件, 辅助模型区分“输入/修改/清空”等意图; **功能依赖 (Functional Dependency)** 描述控件间的功能关联, 例如广告弹窗右上角的“关闭 (X)”图标与 ADVERTISEMENT 容器建立依赖关系, 使模型学习“如何关闭弹窗/广告”这类意图导航。

多维属性与状态向量 (Attributes & State Vectors) 为支持 UI Agent 决策, 本文为每个 bbox 附加多维属性与交互状态信号, 核心是一个交互状态三元组: **Activated** 标注开关开启、Tab 选中、单选框勾选等状态; **Interactable** 区分可交互与置灰不可交互控件; **Filled** 标识输入框/选择器是否已有内容, 辅助判断执行“输入”还是“修改”。此外, 对于 ICON 类补充图标释义 (结合上下文填写象形含义, 如“房子 → 主页”), 并对 BUTTON/TEXT_INPUT 记录内部文本, 用于增强视觉编码器与文本空间的对齐目标。

人机协同标注与一致性校验 (Human-in-the-Loop) 为保证标注效率与精度，采用了半自动化标注 workflow：OCR 预处理生成文本 bbox 与内容，检测模型生成候选控件框，属性预测模型补全类别与状态；标注员进行校验与微调，并引入一致性检查机制（例如外部注释必须有指向目标、关系图无孤立节点、bbox 紧致且合法），以降低噪声样本对训练的负面影响。

3.4 模型架构与训练策略

在数据工程基础上，本文进一步从架构与训练两方面优化模型的高分辨率感知与坐标生成能力，以满足 GUI 小目标定位与中文文本识别的需求。

3.4.1 视觉编码器与分辨率自适应：AnyRes 机制

GUI 截图包含密集文字与小图标，且移动端屏幕常呈现高长宽比（竖屏）。若直接将原图缩放到视觉编码器的固定正方形输入（如 224×224 或 336×336 ），会产生不可逆的信息损失：细小图标与字体被压缩后趋于同质化，导致 Referring 依赖的文本语义对齐变弱、Grounding 需要的像素级几何细节丢失，进而表现为定位偏差与相邻控件混淆。

为此，本文采用动态分辨率（AnyRes）机制（参考 InternVL-2 等工作中的高分辨率视觉输入处理思路^[65]），其核心思想是同时提供全局布局视野与局部高分辨率细节，并将二者的视觉特征统一送入语言模型。具体而言，先对原始截图进行全局缩放（Global Resize）生成一张缩放后的全图，用于捕捉导航栏、内容区、弹窗遮挡等全局布局关系，提供稳定的页面结构先验；然后依据原图长宽比自适应选择网格（如 1×2 、 2×2 或 2×3 ）进行网格切分（Grid Cropping），在原始分辨率空间切分得到多个局部 Patch，每个 Patch 再缩放到视觉编码器的合适输入尺寸，使编码器能够清晰感知按钮文字、图标边缘与细粒度状态差异；为避免“看清局部但不知道其在整屏哪里”的问题，再为每个 Patch 附加其网格索引/相对位置编码（Patch Position Encoding），使语言模型在推理时能够对齐“局部细节 $\leftrightarrow$ 全局位置”；最后分别提取全局图与各局部 Patch 的视觉特征序列并在 Embedding 层进行拼接（或按顺序组织后拼接）作为统一的视觉 token 输入语言模型，使模型既能利用全局图理解页面结构，又能从局部 Patch 读取细小文字与图标细节，从而同时提升语义理解与精确定位。

AnyRes 带来的主要代价是视觉 token 数量增加，从而提升计算开销。本文在网格数量选择上遵循“足够看清关键细节”与“控制推理成本”之间的折中：在典型竖屏场景下优先采用少量 Patch 覆盖主要区域，以在可接受的计算预算内显著提升 Grounding 稳定性与中文 OCR 相关的 Referring 准确率。

3.4.2 坐标表示与定位 Token 设计：文本化坐标生成

为充分利用自回归语言模型的生成能力，本文采用文本化坐标表示，将 bbox 输出为 0–999 范围的归一化整数序列（即 1000 级离散化，如 `<box>250, 500, ...</box>`）。同时引入 `<|box_start|>`、`<|box_end|>`、`<|ref_start|>` 等特殊 Token，区分普通文本生成与定位任务生成，降低坐标串与自然语言串的混淆。

其中，坐标归一化的目的在于消除不同设备分辨率与长宽比带来的尺度差异：将像素坐标映射到固定范围后，模型学习到的是“相对位置与相对尺寸”的几何概念，而非对某一固定分辨率的硬编码记忆。这使得同一指令在不同屏幕尺寸（例如 1080×1920 与 1440×2560 ）下仍能输出一致的定位结果，并便于与数据工程中来自不同来源的数据（开源/闭源/合成）进行统一标注与混合训练。同时，使用整数文本序列输出坐标可避免额外回归头设计，并与语言模型的离散生成框架天然兼容。

特殊 Token 的引入则承担“结构化约束与可解析性”两项作用：一方面，`<|box_start|>`、`<|box_end|>` 等标记显式划分坐标片段的边界，减少模型将坐标数字与自然语言混写导致的格式错误；另一方面，这类标记使下游系统能够以确定性规则解析模型输出，将 bbox 作为可执行的动作目标（例如点击/框选），从而降低“输出不可用”带来的失败率。对于训练而言，特殊 Token 也相当于为定位任务提供了更清晰的任务提示（task delimiter），有助于缓解定位生成与对话生成之间的干扰，提升坐标生成的稳定性与一致性。

3.4.3 双阶段混合微调（DMT）：GUI 注入与通用对齐

为兼顾 GUI 能力与通用对话推理能力，本文采用双阶段混合微调（Dual-stage Mixed Tuning, DMT）策略^[3]。该策略的出发点是：当模型同时学习“专用能力”（GUI 定位、OCR 密集对齐）与“通用能力”（多模态对话、指令遵循与推理）时，简单的多任务混合训练往往会引发两类问题：在数据量较大或任务差异较大时容易出现能力冲突（不同任务目标相互干扰，导致某些能力不升反降）；若采用顺序微调，模型又容易发生灾难性遗忘（后续通用对齐覆盖掉前期学到的 GUI 定位能力）。DMT 通过“先专用、再混合回放”的方式，在两者之间取得平衡。

阶段一：GUI 领域知识注入（Domain Adaptation）。训练数据 100% 为 GUI 相关数据（开源清洗数据 + 闭源精标数据 + OCR 密集任务），以 bbox 预测与文本对齐为主；训练中冻结视觉编码器大部分参数，重点微调语言模型部分，使模型快速获得稳定的屏幕元素感知与坐标生成能力。**阶段二：通用能力恢复与对齐（General Alignment）。**在保持 GUI 能力的同时引入通用多模态对话数据（约

80–85%)，并按混合比例 k 回放阶段一的高质量 GUI 样本（约 15–20%）。 k 的取值需要权衡灾难性遗忘与能力冲突： k 过低则定位精度回落明显， k 过高则通用对话与推理能力受到过强 GUI 偏置；本文实践表明，回放比例稳定在 15–20% 区间即可在保持定位精度的同时不显著损伤通用能力。

从数据混合角度看，已有研究表明：在低资源条件下，多源数据混合可能带来协同效应；而在高资源条件下，简单扩大混合数据总量更容易触发能力冲突，且性能退化往往更多来自“数据总量与任务差异”的叠加，而非比例本身。因此，阶段二采用“通用为主、GUI 少量回放”的设计：一方面继续提升通用对话与推理能力，另一方面用比例 k 的 GUI 回放样本提供持续的定位与 OCR 对齐约束，显式缓解遗忘。同时，相比直接多任务学习，DMT 更能保留通用能力；相比纯顺序微调，DMT 又能通过回放显著降低专用能力遗忘，从而实现 GUI 专用能力与通用能力的更优折中。

3.5 实验与评估

3.5.1 评测任务与指标

围绕 Referring 与 Grounding 两项核心能力，本文采用控件级评测作为主要指标。Referring 准确率定义为：给定目标 bbox，模型输出的类别/功能/文本描述与标注答案一致的比例；对于含 OCR 文本的样本，额外关注关键实体与短语的匹配正确率。Grounding 准确率定义为：给定自然语言指令，模型预测 bbox 与标注 bbox 达到预设重叠阈值（如 $\text{IoU} \geq \tau$ ）且命中目标控件的比例；同时统计在密集小控件场景下的误差分布（偏移量、误命中率）。

其中，IoU（Intersection over Union）用于度量预测框与标注框的空间重叠程度，定义为两者交集面积与并集面积之比：

$$\text{IoU} = \frac{\text{area}(B_{\text{pred}} \cap B_{\text{gt}})}{\text{area}(B_{\text{pred}} \cup B_{\text{gt}})} \in [0, 1].$$

在 GUI 场景中，许多控件（如图标、页面指示器、滑块把手）尺寸较小且相邻密集，轻微的像素级偏移就可能导致 IoU 显著下降。因此本文同时报告不同阈值下的结果：较宽松的 $\text{IoU} \geq 0.1$ 更关注“是否命中正确控件区域”，而更严格的 $\text{IoU} \geq 0.5$ 则更强调框的几何精确度与边界贴合度。评测样本覆盖前 200 应用的高频页面与交互组件，包含中文文本、弹窗浮层与多状态控件等困难模式，以检验模型在真实分辨率与真实布局下的泛化能力。

3.5.2 实验结果与分析

为验证多源数据工程的有效性，实验设计主要从数据维度进行对比：开源清洗数据、闭源精标数据及其组合（并配合负样本、关系图谱与状态向量等监督信

息)。

表3-2从数据维度汇总了不同数据配置下的 Grounding 与 Referring 性能。可以看到，仅使用基线模型时两项指标均较低；引入开源清洗数据后，Grounding F1 从 0.324 提升至 0.557，Referring F1 从 0.523 提升至 0.612；进一步在开源数据基础上叠加闭源精标数据后，Grounding F1 达到 0.846，Referring F1 达到 0.905，两项指标均获得显著累计提升。需要说明的是，本表为“基线 →+ 开源 →+ 开源 + 闭源”的累加式消融，因此第三档的增益反映的是闭源精标数据对覆盖与质量的整体补足，而非“融合”这一动作本身的单独收益；后续若有条件单独评估“基线 + 闭源”配置，可进一步分离两类来源的贡献。

表 3-2 不同数据配置下的 Grounding 与 Referring 性能对比。

数据配置	Grounding F1	Referring F1
Baseline	0.324	0.523
Baseline + 开源数据	0.557	0.612
Baseline + 开源 + 闭源	0.846	0.905

表3-3展示了模型在各类型 UI 控件上的 Grounding 性能。可以看到，在 IoU 阈值为 0.1 时，整体 F1 达到 0.923；在更严格的 $\text{IoU} \geq 0.5$ 阈值下，整体 F1 仍保持 0.846。其中，按钮、输入框、弹窗、开关等高频交互控件的定位精度较高 ($\text{F1} > 0.94$)，而页面指示器、滑块等小尺寸或形态多变的控件定位难度较大。

表3-4展示了模型在 Referring 任务上的属性预测性能。整体加权平均 F1 达到 0.905，其中“类型”属性预测最为准确 ($\text{F1} = 0.944$)，“内部注释”（控件内显示文本）的识别也保持较高水平 ($\text{F1} = 0.915$)。相比之下，“当前值”属性的召回率较低 (0.551)，主要因为该属性仅在滑块、进度条等少数控件上有意义，样本稀疏且形态多样。

综合表3-3与表3-4的细粒度统计，可进一步归纳两类主要误差来源：(1) 极密集区域的近邻混淆（图标间距过小导致误点相邻控件）、(2) 文本与控件关系未显式建模时的语义歧义（如“用户名/手机号”标签与输入框的绑定不稳定）。对应地，本文在数据工程侧提供了针对性缓解：通过关系图谱与状态向量为控件间关系与页面状态提供显式监督以降低语义歧义；引入负样本与工具校验减少“看起来像可点但不可点”的误命中；同时以多源数据覆盖更多页面布局与控件形态，提升模型在真实分辨率与真实布局下的泛化能力。

表 3-3 各类型 UI 控件的 Grounding 性能 (F1 Score)。

控件类型	数量	F1 (IoU $\geq$ 0.1)	F1 (IoU $\geq$ 0.5)
文本	3768	0.945	0.862
图标	2298	0.855	0.737
按钮	1579	0.972	0.947
图片	347	0.850	0.836
导航栏	298	0.983	0.930
选项区	183	0.945	0.863
输入框	167	0.976	0.946
选项框	132	0.871	0.750
弹窗	64	0.969	0.969
开关	38	1.000	0.947
页面指示器	29	0.724	0.483
滚动选择器	26	1.000	0.962
广告	22	0.909	0.864
地图	15	0.933	0.867
滑块	14	0.714	0.500
日期选择器	13	1.000	1.000
多重滚动选择器	12	1.000	1.000
滑块容器区	7	1.000	0.857
通知	6	1.000	0.500
ALL	9018	0.923	0.846

表 3-4 Referring 任务各属性预测性能。

属性	实际样本数	预测总数	精确率	召回率	F1
内部注释	5773	5619	0.927	0.903	0.915
图标含义	1624	1485	0.898	0.821	0.858
外部注释	1927	1814	0.831	0.783	0.806
当前值	198	146	0.747	0.551	0.634
是否不可交互	585	529	0.817	0.739	0.776
是否已激活	545	487	0.867	0.774	0.818
类型	10072	9853	0.954	0.934	0.944
加权平均	20724	19933	0.923	0.889	0.905

3.6 本章小结

本章面向移动端 GUI 这一“控件密集、文字细小、状态易变”的垂直场景，提出了一套提升视觉语言模型屏幕理解能力的系统方案，围绕 Referring 与 Grounding 两项核心能力给出从数据到训练的完整落地路径。本文的主要工作与贡献可概括为：

- 多源数据工程 Pipeline：从任务需求出发构建“收集 → 结构化初始化 → 混合标注与属性补全 → 任务/QA 生成 → 质控迭代”的数据流程，融合开源清洗数据（RICO/CLAY、MobileViews、OS-Atlas）^[5,21–23]、闭源精标数据（v1/v2）与必要的合成/重写样本，兼顾分布覆盖与质量可控，为 GUI 能力持续迭代提供数据基础。
- 面向可解释语义与可执行定位的标注规范：提出细粒度控件分类学（23 类核心控件）、有向关系图谱（如标签–控件绑定、值–控件绑定与功能依赖）以及多维属性与状态向量（Activated/Interactable/Filled、图标释义、内部文本等），并通过人机协同与一致性校验降低噪声，显式缓解 GUI 中的语义歧义与“看似可点但不可点”的误监督问题。
- 高分辨率感知与坐标生成训练设计：采用 AnyRes 分辨率自适应机制保留全局布局与局部细节，并以文本化坐标与专用 Token 约束 bbox 生成的可解析性；结合 DMT 双阶段混合微调在 GUI 专用能力注入与通用对齐之间取得平衡，缓解能力冲突与灾难性遗忘。
- 系统评测与量化验证：在 Top 200 应用的真实页面分布上进行控件级评测，给出不同数据配置与细粒度控件/属性维度的结果统计。实验表明，引入开

源数据与闭源精标数据可显著提升整体性能（Grounding F1 由 0.324 提升至 0.846，Referring F1 由 0.523 提升至 0.905），并揭示了密集小控件近邻混淆与文本绑定歧义等关键误差模式，为后续 UI Agent 的任务规划与执行奠定基础。

需要指出的是，本章方法更偏向以高精度、可执行、可校验的像素级监督为核心，强调“看得准、点得稳”的底层能力建设，这使其在 GUI 垂直场景中效果显著，但也存在两点局限：（1）对图像背后隐含的事实、概念与关系缺乏直接监督，难以覆盖“先识别再检索/回忆、再筛选推断”的知识推理链路；（2）精细标注与状态/关系建模具有较强的领域依赖与成本约束，当任务从 GUI 扩展到开放世界知识时，仅靠细粒度可执行监督难以在覆盖度与可控性之间取得平衡。基于这一观察，下一章（第4章）将进一步面向世界知识能力提升，围绕对齐可信度与推理密度构建更可扩展的数据组织与增强策略，为后续统一的数据合成框架抽象奠定实践基础。

第 4 章 世界知识能力提升方案

延续第3章在**感知端**沉淀的“高精度像素级监督”方法基座，本章把研究视角从“看得清、定位稳”切换到“懂得对、推得通”——也即数据能力光谱另一端的**推理端实证**。如果说 GUI 任务考验的是模型对可见证据的精确绑定，那么世界知识任务则要求模型在视觉证据之外进一步引入外部知识，并在多步条件约束下完成可验证的推理。本章作为“两端实证”路线的另一极，在数据组织、监督形态与质控目标上与第3章形成显著互补：前者强调“几何精度 + 状态绑定”，本章强调“可验证对齐 + 过程性监督”。两章共同为后续第5章 Auto-Evol 统一框架的抽象提供互补的实证基础——其差异正是框架“共通骨架”得以涌现的前提，而其共通的工程模块（结构化初始化、相关性过滤、原子化任务分解、多维校验、失败回流）则将在第5章被显式抽象为可跨任务迁移的方法学。

4.1 任务定义与核心挑战

当多模态模型从“描述图像”走向“理解图像背后的事实、概念与关系”时，世界知识便成为关键瓶颈：模型不仅要识别画面中的具体实例，还要将其锚定到外部知识空间中的抽象事实并完成多步推理。本节先给出本文对世界知识能力的定义并以一个直观案例阐释其与“纯视觉描述”的差异，再归纳世界知识注入在实践中的三大核心困境，并据此明确本章的研究目标与方法路线。

4.1.1 任务定义：从“看见”到“理解”

本文将**世界知识** (World Knowledge) 定义为对物理世界、社会文化、历史事件、科学技术等领域的事实、概念、关系与常识的综合掌握，其本质是一个庞大且交织的知识网络。相比第3章关注的“可见语义与几何定位”，世界知识能力要求模型在视觉证据之外进一步引入外部知识，并在“识别-调用知识-条件推断”的链路上稳定输出。

图4-1给出了一个直观的对比如例：对于经典电影《泰坦尼克号》的标志性场景，缺乏世界知识的模型仅能给出浅层描述——“一个男人和一个女人站在船头”；而具备世界知识的模型则能识别出这是 1997 年上映的电影《泰坦尼克号》，由詹姆斯·卡梅隆执导，主演为莱昂纳多·迪卡普里奥与凯特·温斯莱特，并进一步理解这一场景描绘了主角杰克与露丝在船头“飞翔”的浪漫时刻，以及该影

片在全球取得的商业成功与文化影响力。这种从“看见”到“理解”的跃迁，正是世界知识赋予模型的核心能力，也是本章后续数据合成与训练优化的直接监督目标。



图 4-1 有无世界知识的模型响应对比。无世界知识：“一个男人和一个女人站在船头。” 有世界知识：“这是 1997 年上映的电影《泰坦尼克号》的经典海报，由詹姆斯·卡梅隆执导，主演是莱昂纳多·迪卡普里奥和凯特·温斯莱特……”

4.1.2 三大核心困境

提升 VLM 的世界知识能力并非简单“增加数据量”即可解决，世界知识注入在实践中往往同时受到三大困境的制约。**困境一是知识整合与收集(Integration)**：目前的世界知识通常存在于庞大的文本语料库或结构化知识图谱中，知识源虽然丰富，但要从中抽取并组织成可被模型学习的训练样本并不容易。其难点在于知识高度分散且表达形式异构（不同来源对同一实体的称呼、粒度与侧重点不一致），同时存在噪声与时效性差异；直接“搬运知识”难以保证与视觉内容可验证对应，导致样本在训练时容易引入错误监督或不可学习信号。**困境二是视觉与语言对齐 (Alignment)**：大语言模型往往已具备一定的世界知识能力，但视觉侧未必能将图像中的具体实例 (Specific Instance) 与文本知识中的抽象描述 (Abstract Description) 精确关联。例如，图像中出现一只特定的鸟，文本知识可能包含该鸟类的学名、习性与分布范围，但模型难以将这些抽象属性稳健地“落到”当前图像实例上，从而出现“知道但看不出来”或“看出来但说不对”的错配；同一实体在不同视角、光照、遮挡或风格化图像中呈现的显著差异，也会放大对齐难度并影响泛化能力。**困境三是多跳推理能力 (Reasoning)**：许多复杂世界知识问题需要模型进行多步推理，将多个知识点链接后再得出结论。例如，回答“图中这位导演拍摄的、获得奥斯卡最佳影片的电影是哪部？”需要模型先

识别图中人物为某位导演，再检索或回忆其作品列表，最后按“获奥斯卡最佳影片”条件进行筛选得到唯一答案。该过程要求模型同时具备稳定的实体识别、可控的知识调用以及可执行的条件推断链路，对当前 VLM 仍是显著挑战。

4.1.3 研究目标与本章路线

针对上述三大困境，本章在数据工程层面给出系统性应对：以**知识类别框架**约束知识收集的覆盖与边界（应对 Integration），以 **caption 中间表征 + 相关性过滤**建立稳健的视觉-知识锚点（应对 Alignment），以 **RecQA / KnowQA / FinalQA 三类任务分解 + Think/CoT 过程监督**显式拆解并训练多步推理链路（应对 Reasoning）。本章后续将依次展开知识类别框架、世界知识数据 Pipeline、训练与实验，并在 Chinese SimpleVQA 与 SimpleVQA 等基准上给出量化验证；本章沉淀的可验证对齐、过程性推理监督与中间表征 caption 等模块，将与第3章在感知端的实践共同构成第5章 Auto-Evol 统一框架的实证基础。

4.2 知识类别框架

世界知识增强的首要前提，是建立一个可覆盖、可扩展、可操作的知识类别框架。若缺乏统一的类别坐标系，世界知识将以“零散事实”的形式分布在不同来源中，不仅难以进行系统性采样与补全，也难以在训练与评测中对模型能力进行可解释的归因分析。因此，本文构建分层分类体系，包含 7 个大类与 40 个子类（如图4-2所示），用于约束数据构造过程并为后续框架化的数据 Pipeline 提供统一接口。

类别制定的作用与必要性主要体现在三方面：一是**指导词条生成与采样**，在每个子类的定义约束下，词条生成能够被限定在明确语义边界内，避免“概念混淆”（如将作品名误作人物名）与“粒度漂移”（如将系列与单部作品混用），从而提升词条集合的可控性与可复用性；二是**支持长尾覆盖与迭代补全**，按子类统计实体与样本分布可显式暴露稀缺类别与薄弱子类，便于后续定向补齐与均衡采样；三是**作为训练/评测的统计维度**，类别标签为分析不同知识域的对齐难度、误差模式与泛化瓶颈提供了可解释的分组依据。

为保证后续“词条生成 → 图片收集 → 标注与 QA 构造”的一致性，本文为每个大类与子类均给出可操作的边界定义，定义内容包括：覆盖范围（该类包含哪些实体/概念）、排除规则（易混淆但不属于该类的情况）、命名规范（中英文/别名/译名的处理方式）以及典型示例（用于提示生成与校验）。例如，建筑景观/地标建筑强调“可定位的实体建筑与场所”，并排除“抽象建筑风格”；文化娱乐/电影以“独立作品”为基本粒度，区分系列名与单部片名；品牌商标/商业 Logo 强调“可识别的品牌标记”，并区分公司主体与产品线名称。




图 4-2 世界知识类别框架（7 个大类与 40 个子类）。

在该框架下，代表性大类如下：

- 自然景观：自然形成的地理实体与景观要素，强调可定位与可辨识度（如河流、山脉、森林、沙漠等）。
- 生物：具有明确物种/类群归属的生命体实体，强调可用学名/别名统一归并（如知名动物、植物、真菌等）。
- 建筑景观：人造建成环境中的可识别实体，强调“具体建筑/场所”而非抽象风格（如地标建筑、宗教场所等）。
- 人物：具有可追溯身份的真实人物实体，强调同名消歧与多语别名对齐（如政治人物、演艺明星、历史名人等）。
- 品牌商标：可被视觉识别的品牌标记与商业符号，强调品牌与产品的边界区分（如商业 Logo、产品包装等）。
- 文化娱乐：文化作品及其衍生实体，强调作品粒度与系列关系的规范化（如电影、游戏、动漫、书籍等）。
- 科学技术：科技相关的可识别对象或现象，强调术语标准化与概念边界（如特定设备、科学现象等）。

该框架为后续章节中的词条生成、图片收集与 QA 构造提供了稳定、可复用的“坐标系”，使世界知识数据构造从零散经验转为可控流程，并为后续框架的建立与扩展提供结构化支撑。

4.3 数据工程：世界知识数据构造 Pipeline

世界知识增强的关键在于“把分散知识变成可学习的多模态监督”。本文设计了如图4-3所示的世界知识数据构造 Pipeline，该流程包含词条生成与图片收集、图片 Caption 生成、图文相关性过滤、QA 对生成与 QA 对质量过滤等核心环节，形成从知识源到可训练数据的完整转化路径。

4.3.1 词条生成与图片收集：从知识域到视觉证据

对应图4-3中的“词条生成和图片收集”环节，本文首先在前述知识类别框架的约束下，为每个子类生成可控的词条集合，并围绕词条自动化收集图片，以形成“实体 $\leftrightarrow$ 视觉证据”的锚点，为后续图文对齐与知识学习打下基础。具体流程包括三步：首先进行**类别制定**，基于前述分类体系的定义边界确定每个子类的覆盖范围与排除规则，从源头保证后续词条生成与样本采样的语义一致性与




图 4-3 世界知识数据构造 Pipeline。

可追溯性；接着进行**词条生成**，采用大模型依据类别/子类定义生成“最热门、最具公众关注度”的核心词条（每类约 150~200 个）以覆盖主流高频知识，并由人工补充新近出现或相对冷门但具研究价值的词条，以提升长尾覆盖并缓解仅学习头部概念带来的偏置；最后进行**图片收集**，针对每个词条实现一个自动化的图片收集 agent 脚本，调用 Google 图片搜索抓取该词条返回结果中的前 100~500 张图片，将抽象词条落到具体视觉实例上，并保留来源、分辨率、时间等元信息以支持去重与质量追踪。在这一阶段，数据工程的目标是“实体可控”与“图像高质量”：实体可控保证知识监督可追溯，图像高质量保证视觉侧对齐不被噪声主导。

4.3.2 图片 Caption 生成：融合视觉描述与知识背景

对应图4-3中的“图片 CAPTION 生成”环节，本文为每张自动抓取的图片生成结构化 caption，其作用不仅是“生成更丰富的描述”，更是为后续多个关键环节提供可依赖的中间表征：(1) 图文相关性过滤需要 caption 帮助模型判断图片是否真的与词条匹配；(2) 知识要素提取可从 caption 中抽取实体属性、别名与背景事实；(3) QA 对生成可将 caption 作为问题构造与答案验证的上下文依据。

尤其在相关性过滤场景下，由于图片是自动抓取的，实际会混入与词条无关的图片（例如同名歧义、检索噪声、相似外观实体等）。仅依赖视觉模型直接判别相关性容易受限于大模型自身的识别能力与先验偏差，因此本文将 caption 与词条知识一并提供给过滤模型作为判据，从而提升过滤的稳健性与可解释性。

图4-4给出了 caption 数据的一个示例。可以看到，caption 不仅描述了画面中的关键视觉元素（两名士兵、英军制服、草地与田野等），还补充了与该视觉内容强相关的背景知识（电影名称、上映年份、导演、拍摄手法与剧情要点）。这类“视觉描述 + 背景知识”的融合表达，一方面为后续相关性过滤提供了更可验证的判断依据，另一方面也为知识要素提取与 QA 构造提供了可复用的文本上下文。




图 4-4 Caption 数据示例（电影《1917》相关画面）。

PROMPT: 请仔细观察这张图片，描述其中的主要内容，并提供相关的背景知识。

RESPONSE: 这张图片来自电影《1917》(2019)。在图片中可以看到两名士兵穿着英军制服，躺在草地上。背景是一片开阔的田野，远处有一些模糊的植被和空旷的天空。

《1917》是一部关于第一次世界大战的战争片，由萨姆·门德斯执导。这部电影以其独特的拍摄手法闻名，采用了一种类似单镜头的方式，使观众感觉仿佛是在实时跟随士兵的旅程。影片的情节围绕着两名年轻的英国士兵，他们接到一项看似不可能完成的任务：穿越敌方领土，传递一条至关重要的信息，以阻止一场可能导致 1600 人阵亡的伏击。

影片的视觉效果和沉浸式体验获得了极高的评价，尤其是在构建紧张感和真实感方面。电影中展现了战争的残酷和士兵们在战场上的勇气与牺牲，获得了很多观众和评论家的好评。

4.3.3 图文相关性过滤：保证视觉-知识对齐质量

对应图4-3中的“图文相关性过滤”环节，本文通过两步保证数据质量。其一是**相关性分数制定**：采用大模型进行判别，并设置 1~5 的离散相关性分数以刻画“图片 ↔ 词条”的匹配强度——5 分表示完全相关（图片直接包含标签内容），4 分表示高度相关（作品/组成部分等紧密关系），3 分表示中等相关（可联想但不直接对应），2 分表示低度相关（需较强推理才能建立联系），1 分表示完

全不相关；模型在输出分数时同时给出简要理由，并采用固定格式（如“相关性分数：[分数]”）便于程序解析与自动化处理。其二是**阈值化过滤与尽可能保留**：考虑到大模型判别仍存在误差，本文并非“一刀切”地仅保留最高分样本，而是通过设定分数阈值与抽样复核策略，尽可能保留潜在相关图片（如 4 分、部分 3 分样本），以在覆盖率与噪声控制之间取得平衡。过滤后的样本将进入后续 QA 构造，从源头降低“错图错标”导致的对齐噪声。

过滤效果对比与人工评估。 为量化“相关性分数”策略对数据保留率与幻觉噪声的影响，本文从原始抓取结果中随机抽取 2000 条“图片-词条”样本进行对比实验。若不设置相关性分数、仅让模型输出“相关/不相关”的二分类判断，则最终只能保留约 1009 条数据；而在制定 1~5 相关性分数并保留 3 分及以上样本后，可保留约 1511 条数据，显著提高可用数据覆盖。

进一步地，本文对上述 2000 条样本及其不同过滤策略后的保留子集进行人工抽检，主要关注上一步生成的 caption 在对照词条与图片时是否出现知识性幻觉（例如模型不认识/误识别实体，从而编造与词条不符的背景事实）。本文将幻觉程度划分为三档：几乎没有幻觉、有部分幻觉、大部分幻觉。统计结果如表 4-1 所示。

表 4-1 不同图文相关性过滤策略下的样本保留与 caption 幻觉程度统计（括号内为占比，保留 1 位小数）。

数据设置	样本数	几乎无幻觉	部分幻觉	大部分幻觉
过滤前（未过滤）	2000	1231（61.6%）	511（25.6%）	258（12.9%）
直接相关性过滤（二分类）	1009	733（72.6%）	196（19.4%）	80（7.9%）
相关性分数过滤（≥3 分）	1511	1213（80.3%）	235（15.6%）	63（4.2%）

可以看到，相关性分数的制定在保留更多数据的同时，“几乎无幻觉”样本占比也显著上升，并有效降低“部分/大部分幻觉”样本比例。这说明分数化判别相比二分类更能缓解因大模型自身不认识或误识别带来的误判与幻觉噪声，从而在覆盖率与对齐质量之间取得更优平衡。

4.3.4 QA 对生成：从描述到三元组任务

对应图 4-3 中的“QA 对生成”环节，为了解耦感知与推理，本文构造三类互补问答对：

- RecQA（Recognition QA）：对应“模型看见图片”的能力，问题围绕“这是谁/这是什么/来自哪里”等识别任务，答案为实体或关键属性。其目标是

将视觉特征稳定锚定到词条实体，解决“看到但叫不出名字”的问题。在生成时，模型输入包括图片、图片对应的 caption、目标词条以及词条所属类别，用于约束识别问题的指向性与答案空间。

- **KnowQA (Knowledge QA)**：对应“模型知道关于该实体的世界知识”的能力，问题强调外部知识（历史、文化、科学属性等），形式上可不依赖视觉信息，但与图片实体强相关。其目标是向模型注入可泛化的背景事实，解决“认识了但不了解”的问题。在生成时，模型输入为 RecQA 问答对与 caption，并要求其基于 RecQA 的答案（已识别实体）提出相关知识问题，从而将知识提问锚定在正确实体上。
- **FinalQA (Reasoning QA)**：对应“模型理解图片并能调用知识推理”的能力，问题需要“先识别再用知识推理”，可是一跳或多跳链路（如识别实体 → 回忆知识 → 条件筛选）。其目标是打通 RecQA 与 KnowQA 形成的知识链路，推动模型从“描述/识别”走向“解释/推断”。在生成时，模型输入同时包含 RecQA 与 KnowQA 两类 QA，引导其融合“识别结论 + 知识要点”构造最终问题与答案，显式贯通两阶段信息。

三类 QA 分别对应不同能力层次：RecQA 偏感知/识别，KnowQA 偏理解/知识，FinalQA 偏推理/筛选。这种拆分避免模型直接学习“图像 → 最终答案”的捷径，从而提升泛化与可解释性。

图4-5展示了三类 QA 在同一实体上的组织方式。RecQA 首先要求模型从图像中识别出“戴着条纹围巾的光头男性角色”为格鲁 (Gru)；KnowQA 进一步询问与该实体相关、但必须依赖外部知识才能回答的问题（例如《神偷奶爸》系列的制作公司）；FinalQA 则将二者合并为一步推理问题，使模型必须先完成识别，再调用知识得到最终答案。此外，为了促进可解释推理与避免“直接背答案”，本文还构造带有简要推理过程的 FinalQA (FinalQA with CoT)，要求模型先给出识别结论，再给出问题答案。

RecQA (基于识别的问答对)

PROMPT: 图片中戴着条纹围巾的光头男性角色是谁?

RESPONSE: 格鲁 (Gru)。

KnowQA (仅基于知识的问答对)

PROMPT: 格鲁 (Gru) 所在的《神偷奶爸》系列电影是由哪家公司制作的?

RESPONSE: 照明娱乐 (Illumination)。

FinalQA (合并 RecQA 与 KnowQA 的一步推理问题)



图 4-5 三类 QA 与 FinalQA with CoT 示例（格鲁/Gru）。

PROMPT: 图片中戴着条纹围巾的光头男性角色所在的系列电影是由哪家公司制作的?

RESPONSE: 照明娱乐 (Illumination)。

FinalQA with CoT (带简要推理过程)

PROMPT: 图片中戴着条纹围巾的光头男性角色是照明娱乐 (Illumination) 制作的哪部动画电影系列的主角?

RESPONSE: 图片中戴着条纹围巾的光头男性角色是格鲁 (Gru)，他是动画电影系列《神偷奶爸》的主角。

4.3.5 QA 对质量过滤：确保训练数据可靠性

对应图4-3中的“QA 对质量过滤”环节，本文采用多级质控保证知识可靠与对齐有效。**规则约束与质量分数制定**是第一步：本文使用大模型对“问题-答案”对进行规则校验，重点约束包括问题必须同时依赖图像信息与外部知识（既不能纯靠知识回答，也不能纯靠图像即可回答）、问题应当客观明确且无歧义、答案必须唯一且不随时间变化、避免一个问题中同时询问两个子问题等；基于满足程度给出 1~3 的质量分数，3 分表示完全合格，2 分表示勉强合格但必须满足“唯一答案/时效稳定/单问题”这些关键约束，1 分表示不合格；模型输出时给出简要理由并采用固定格式（如“合格分数: [分数]”）便于解析。**低质量过滤与回收**是第二步：对低分样本进行过滤或回收重写，重点剔除多答案、表述模糊、主观化或时效性强的问题，从而保证训练信号的可学习性与评测的一致性。**评测基准去重**是第三步：为避免训练数据与评测基准（如 Chinese SimpleVQA、SimpleVQA）在图像层面发生重叠导致评测泄漏，本文在构造训练集时对评测基准中的图片进行 hash 去重——对训练集与评测集图片分别计算感知哈希（perceptual hash，如 pHash/dHash 等）并以哈希值作为指纹建立索引，若训练样本图片与评测基准图片哈希完全一致则直接从训练集中剔除；同时可进一步基于哈希间的汉明距

离进行相似度判别，在距离小于阈值时视为近重复（如压缩、裁剪、分辨率变化导致的轻微差异）并一并过滤，从源头保证评测的独立性与结论可信度。

4.4 训练与实验：从数据类型消融到 CoT 对齐

本节将训练策略与实验分析合并阐述：首先通过消融实验验证不同数据类型对世界知识能力的影响；随后针对推理指标“增益不显著甚至下降”的现象，引入带推理过程的 Think/CoT 数据并扩充数据分布，给出改进后的结果；最后报告在 Chinese SimpleVQA 与 SimpleVQA 上的最终性能，并分析与强基线之间的差距。

4.4.1 多阶段、多来源数据构建

训练过程中，本文采用多批次策略逐步扩充数据分布。**Batch 1 (Part1)** 使用最强模型构建第一批数据，确保高精度与高一一致性；**Batch 2 及后续 (Part12、Part123)** 则引入不同模型与更多未见词条扩充数据分布，降低单一模型偏置并提升长尾覆盖。

同时，在同一批次的数据构造 Pipeline 中，本文也会针对不同环节的侧重点选用不同模型，以进一步降低单一模型带来的偏置风险：词条生产依赖知识覆盖更强的文本模型 gpt5；caption 生成使用当时更强的多模态模型 Gemini-2.5-pro 与 gpt-4o 以提升视觉描述与背景知识补全质量；后续 RecQA/KnowQA/FinalQA 的生成更偏向于从 caption 中抽取与融合知识，因而采用指令遵循更强且生成效率更高的 Gemini-2.5-flash 以提升规模化产出稳定性。

4.4.2 实验一：数据类型消融与冲突分析

本实验的目的在于确定不同数据类型对世界知识能力是否具有正向影响，并定位可能的任务冲突。评测指标包括识别侧 (Correct、Accuracy、F1) 与推理侧 (Correct、Accuracy、F1)，分别对应 Recognition 与 Final 两类任务。

实验结果如表4-2所示，可以得到以下结论：

- 与强基线仍有差距：尽管数据增强带来提升，但与 Qwen2.5-VL-7B 相比^[3]，各项指标仍存在明显差距，说明世界知识能力提升仍受限于模型容量、数据覆盖与对齐质量等因素。
- Image Caption 对识别有正向作用：加入 caption 类数据能为识别任务提供更稳定的视觉-文本锚点，使 recognition 相关指标相对 base 获得稳定提升 (F1_Rec 从 28.1 提升至 31.4–33.1)。

- 仅监督最终答案的 FinalQA 未观察到稳定推理增益：在不引入显式推理过程的 Direct Answer 形式下，加入 FinalQA 的两个配置（all、RKFQA）相较 base 在 final 指标上分别为 -0.7 与 +0.1，未呈现稳定增益；同时，移除 FinalQA 的 RKQA 配置出现更明显的回落（F1_Final 由 37.0 降至 35.2），提示在没有显式推理监督的情况下，单纯调整 RecQA/KnowQA/FinalQA 组合难以稳定提升推理能力，这一现象指向“需要更显式过程监督”的改进方向（详见实验二）。
- 短路映射风险与任务冲突：当 FinalQA 仅强调“直达最终答案”时，模型容易学习“图像特征 → 答案”的短路映射，与 RecQA 对实体识别与稳健锚定的目标存在潜在冲突；同时识别不稳又会反过来限制 FinalQA 的推理上限。这一假设也在实验二（引入 Think/CoT 后 final 指标显著回升）中得到进一步印证。

表 4-2 实验一：Part1 数据与不同数据类型配置的消融结果（Chinese SimpleVQA）。Rec 表示 Recognition；Acc 表示 Accuracy；Part1 表示第一批数据；all 表示全部类型数据；e 表示训练轮次；RKF 分别表示 RecQA、KnowQA 与 FinalQA。

Model	Correct_Rec	Acc_Rec	F1_Rec	Correct_Final	Acc_Final	F1_Final
Qwen2.5-VL-7B	41.3	44.6	42.9	39.5	42.1	40.8
Ovis2.5_9B_base	27.9	28.3	28.1	36.8	<u>37.2</u>	37.0
Ovis2.5_9B_part1_all_e1	<u>32.9</u>	<u>33.3</u>	<u>33.1</u>	36.3	36.3	36.3
Ovis2.5_9B_part1_all_e2	32.2	32.8	32.5	36.2	36.2	36.2
Ovis2.5_9B_part1_RKFQA_e1	31.2	31.6	31.4	<u>37.1</u>	37.1	<u>37.1</u>
Ovis2.5_9B_part1_RKQA_e1	31.6	32.0	31.8	35.2	35.3	35.2

4.4.3 实验二：引入 Think/CoT 与数据扩充的改进效果

由于实验一中推理指标不升反降，我们进一步验证推理过程监督的作用。核心观察是：当 FinalQA 仅监督最终答案时，模型更容易“记答案”；而当 FinalQA 要求输出简要推理过程（Think/CoT）^[33]，模型被迫先完成识别再调用知识，从而更有效地提升 final 相关指标。

基于这一发现，本文采取四项改进思路并在表4-3中给出结果。其一是**保留所有类型数据**：同时保留 caption、RecQA、KnowQA、FinalQA 等多种数据，以维持“视觉锚定 + 知识注入 + 推理贯通”的能力闭环；其二是**扩充未见词条**：继续扩充模型未见过的新词条与长尾实体，提升泛化能力与覆盖面；其三是**FinalQA 增加 CoT 过程**：将 FinalQA 从 Direct Answer 升级为带简要推理过程的形式，使

模型学习“先识别再推理”的过程性能力；其四是**增加 KnowQA 与 FinalQA 密度**：同一张图片可生成多个 KnowQA 与 FinalQA 样本，提高知识链路覆盖与训练信号密度。

表 4-3 实验二：引入 Think/CoT 与数据扩充后的改进结果（Chinese SimpleVQA）。Part12/Part123 表示逐步扩充的数据批次；think 表示 FinalQA 带推理过程的训练设置；Gap 为最优模型相对 Qwen2.5-VL-7B 的提升。

Model	Correct_Rec	Acc_Rec	F1_Rec	Correct_Final	Acc_Final	F1_Final
Qwen2.5-VL-7B	41.3	44.6	42.9	39.5	42.1	40.8
Ovis2.5_9B_part12	33.9	34.3	34.1	36.6	36.7	36.7
Ovis2.5_9B_think_part12	34.4	37.6	35.9	38.6	41.3	39.9
Ovis2.5_9B_think_part123	57.5	60.7	59.0	51.3	54.2	52.7
Gap	+16.2	+16.1	+16.1	+11.8	+12.1	+11.9

从表4-3可见，Think/CoT 对 final 相关指标提升显著（think_part12 相对 part12 在 F1_Final 上提升 +3.2 pt），且在进一步扩充数据分布（Part123）后，recognition 与 final 均获得同步大幅提升（F1_Rec +23.1 pt、F1_Final +12.8 pt）。需要说明的是，Part123 的扩充并非简单“加大量”——其增量主要补齐了 Part12 阶段未覆盖的子类与长尾词条；但训练词条与 Chinese SimpleVQA 评测词条之间的边界仍可能存在部分重合，这一定程度上有利于 recognition 指标的快速跃升，因此该跳幅同时反映了“覆盖扩充”与“过程监督”两类因素的叠加效应，而非 Think/CoT 的单一贡献。即便如此，相对 Qwen2.5-VL-7B 最终 F1_Final 仍取得 +11.9 pt 增益（Gap 行），说明：世界知识能力的提升不仅依赖数据规模与覆盖，更依赖训练信号的结构——显式的推理过程能够促使模型学习可迁移的推理策略，而非在训练分布上“背答案”。后文表4-4与表4-5给出在全量混合 SFT 设置下的最终结果，可作为更严格设置下的参考。

4.4.4 最终结果：Chinese SimpleVQA 与 SimpleVQA

在完成上述训练与数据构造策略后，一共产出了 80w 条数据，在 Chinese SimpleVQA 与 SimpleVQA 上的最终结果，分别见表4-4与表4-5。需要说明的是，最终表中的部分指标相较表4-3有所回落，这并不意味着前述策略失效，而是由于两者对应的训练设置不同：表4-3展示的是仅使用合成世界知识数据进行 SFT 的结果，更偏向对该专项能力的定向优化；而最终结果采用的是面向全部能力、混合全部数据的统一 SFT 设置，在多任务、多分布联合训练下，世界知识相关能力会受到一定的目标稀释与任务干扰。总体上，Ovis2.5_9B 在中文基准上

对 recognition 指标达到并超过部分基线，但在 final 推理指标上与更大模型（如 Qwen2.5-VL-72B）仍存在差距，说明后续仍可从模型容量、检索增强或更高质量推理数据等方向继续提升。

表 4-4 最终结果：Chinese SimpleVQA。Gap 为 Ovis2.5_9B 相对 Qwen2.5-VL-7B 的增益。

Model	Correct_Rec	Acc_Rec	F1_Rec	Correct_Final	Acc_Final	F1_Final
Qwen2.5-VL-7B	41.3	44.6	42.9	39.5	42.1	40.8
Qwen2.5-VL-72B	45.7	48.5	47.1	49.0	53.4	51.1
Ovis2.5_9B (Ours)	47.4	53.6	50.3	48.1	52.1	50.0
Gap	+6.1	+9.0	+7.4	+8.6	+10.0	+9.2

表 4-5 最终结果：SimpleVQA。Gap 为 Ovis2.5_9B 相对 Qwen2.5-VL-7B 的增益。

Model	Correct	Accuracy	F1
Qwen2.5-VL-7B	43.2	45.6	44.3
Qwen2.5-VL-72B	49.4	52.2	50.8
Ovis2.5_9B (Ours)	45.8	52.8	49.0
Gap	+2.6	+7.2	+4.7

4.5 本章小结

本章围绕视觉语言模型在世界知识理解上的不足，系统构建了面向世界知识增强的数据体系与训练框架，为后续统一框架的提出提供了可复用的工程化基础。本文的主要贡献与创新点可概括为：

- 提出可操作的世界知识类别框架：构建 7 个大类、40 个子类的分层分类体系，并强调每个类别/子类的覆盖范围、排除规则与命名规范，从而将“世界知识”从零散事实组织为可采样、可统计、可扩展的结构化坐标系，直接服务于后续词条生成与长尾覆盖。
- 给出端到端的世界知识数据构造 Pipeline：围绕“词条生成 → 自动化图片收集 → caption 生成 → 相关性过滤 → QA 对生成 → 质量过滤”建立稳定

Pipeline。尤其通过 caption 作为中间表征支撑图文相关性判别，并引入 1~5 分相关性评分机制，在覆盖率与噪声控制之间取得更稳健的平衡。

- 设计 RecQA/KnowQA/FinalQA 的三元组任务分解并引入 CoT 监督：从“看见 → 知道 → 理解并推理”的能力递进出发，将感知、知识与推理解耦为三类互补监督信号，避免模型学习“图像 → 答案”的捷径；进一步将 FinalQA 升级为带简要推理过程的 FinalQA with CoT，使模型学习可迁移的推理链路而非记忆答案。
- 通过消融实验揭示冲突并验证改进有效性：实验表明 caption 对识别指标具有稳定增益，而仅提供 Direct Answer 形式的 FinalQA 对推理指标提升不显著甚至下降，反映出 FinalQA 与 RecQA 在训练中存在短路映射带来的冲突；引入 Think/CoT 并扩充未见词条与多问一图数据后，final 相关指标得到显著改善，并在 Chinese SimpleVQA 与 SimpleVQA 上取得具有竞争力的最终结果。

对比第3章以高精度、可执行、强约束的像素级监督为核心、侧重“看得准、点得稳”的数据工程范式，本章进一步将监督重心推进到知识级对齐可信度与推理过程可学习：通过知识类别框架与反向对齐思路实现可控覆盖，以 caption 作为可依赖的中间表征支撑相关性分数过滤与对齐校验，并以 RecQA/KnowQA/FinalQA（及 Think/CoT）将“先识别再推理”的链路显式化，从而在保留更多数据的同时抑制幻觉与短路学习。上述实践不仅丰富了相较 GUI 更“先进”的增强、过滤与过程性约束模块，也沉淀出跨任务可复用的共通骨架（数据源组织、结构化初始化、任务分解与生成、增强/过滤与多维校验、回流迭代）。基于这些共通结构，下一章将进一步抽象并系统化提出完整的 Auto-Evol 多模态数据合成框架，将零散的一次性合成升级为可路由、可评测、可闭环迭代的数据合成系统；并在框架抽象之上，将 Auto-Evol 进一步实例化到 GUI 计算机使用智能体（Computer Use Agent, CUA）场景，依托 OSWorld 评测体系^[6]构建面向**可验证任务合成**的工程系统，跨 LibreOffice 三个 domain（Calc/Impress/Writer）与 VSCode、Chrome 等扩展 domain 验证框架在“看-懂-做”闭环下的可迁移性，并与 EvoCUA^[34]等代表性工作形成方法学层面的互补（详见第5.4节）。

第 5 章 多模态数据合成框架

承接第3章（感知端 GUI）与第4章（推理端世界知识）的两端实证，本章进入数据能力光谱研究路径的第二阶段——**共通抽象 + 综合中段端到端验证**。两端实证回答了“在两类差异极大的任务上各自如何把数据做对”的问题；本章则要回答两个进一步的问题：（1）这两条主线在数据工程层面是否存在可复用的共通骨架？（2）该共通骨架能否在二者之外的、需要“感知 + 推理”协同的综合中段场景下端到端验证其可迁移性？围绕这两个问题，本章先从两端实践归纳共通骨架并抽象 Auto-Evol 多模态数据合成框架（共通抽象），再将其实例化到 GUI 计算机使用智能体（GUI CUA）这一典型综合中段任务上完成端到端验证（中段验证），从而在方法学层面“闭合”前两章工作并向更广任务域辐射。

5.1 研究动机与本章路线

当数据质量取代数据规模成为多模态模型能力提升的主要约束时，零散的“图 → 文/问答”单步合成已难以稳定支撑大规模、可迭代、可验证的训练需求。本章的核心动机正是把前两章在感知端（GUI）与推理端（世界知识）反复出现的可复用模块上升为一个统一的数据合成框架，并将其实例化到一个新的任务场景以验证可迁移性。

5.1.1 从两端实证到共通骨架

GUI 与世界知识两条任务主线在“任务形态”上差异显著：前者要求模型在控件密集、文字细小、状态易变的界面中完成可执行的像素级对齐，数据必须同时提供紧致 bbox、OCR 对齐、关系/状态约束并可自动质检；后者要求模型把图像中的具体实例锚定到知识空间的抽象实体与事实，并在条件约束下完成“先识别再推理”的链路，数据必须保证对齐可验证并尽可能提供过程性约束以避免短路学习。前者强调精度与可执行，后者强调对齐可信与推理贯通；但两套数据工程实践在工程组件上呈现出高度一致的形态——**数据源组织**决定覆盖与可控性、**结构化初始化**沉淀可复用的源信息与锚点、**任务分解与生成**把复杂能力拆为可监督的原子单元、**增强/过滤与多维校验**前置约束训练信号的可信度、**失败回流与闭环迭代**让数据分布随任务瓶颈自适应演化。这一共通骨架正是把“两端工程实践”抽象为统一框架的实证基础。

5.1.2 研究目标与本章路线

基于上述共通骨架，本章提出 **Auto-Evol** 多模态数据合成框架：将“合成数据生成”从单步的“图 → 文/问答”升级为一个包含正反双向链路、任务导向的原子问题生成、代理式生成与进化增强、多维校验与闭环反馈的工程系统。该框架吸收并统一了 ShareGPT4V、MMEvol、SynthVLM、Synthesize Step-by-Step 等工作中可复用的关键组件^[18-20,62]，并以第3章与第4章的数据合成方法为起点，抽象总结出一套可落地、可迭代、可验证的多模态数据合成方法学。在框架抽象之上，本章还将 Auto-Evol 实例化到**综合中段**——计算机使用智能体（Computer Use Agent, CUA）场景下的 GUI 任务（GUI CUA），通过端到端监督微调（Supervised Fine-Tuning, SFT）实验给出量化证据，从而在方法学层面闭合两端工作并验证其跨任务可迁移性。本章后续将依次展开“构造框架”、“模块有效性验证”与“Auto-Evol 在 GUI CUA 领域的实例化”三节内容。

5.2 构造框架

图5-1给出了 Auto-Evol 框架的闭环结构。该框架从数据源侧同时接入原生图片与生成图片两类输入，通过数据初始化统一格式并沉淀生成所需的源信息（可包含自动/人工标注产物），随后进行质量过滤；再将样本路由到“任务导向的原子问题生成”，并按感知、理解、推理三类代理生成多任务指令；最后通过数据增强与数据校验提升多样性、难度与正确性，若校验不过则回流重写/重生成，最终产出可用于监督微调（SFT）与后训练（Post-training）的高质量合成数据。

Auto-Evol 的构造流程可逐模块映射到图5-1的闭环节点。下文结合第3章（GUI）与第4章（世界知识）的实践，依次讲解各模块的作用。

5.2.1 构造流程

(1) 数据源：原生图片与生成图片的双向数据流 Pipeline 顶部同时接入两类数据源：一类是原生图片（真实收集），来自真实应用截图、公开数据集与搜索收集的高清图片，GUI 章使用真实设备分辨率截图以保留小控件细节，世界知识章以“词条 → 图片”的方式确保实体可控；另一类是生成图片（Text-to-Image），当长尾场景稀缺或需要严格对齐时，可采用“文本 → 图像”的反向数据工程，SynthVLM 表明，先清洗 caption 再用扩散模型生成高分辨率图像，并用 CLIPScore+SSIM 筛选，可从源头提高图文对齐度与图像清晰度，从而以更少数据达到更强效果^[10,20,66]。双向数据流的价值在于：正向数据流（图 → 文）擅长覆盖真实分布，反向数据工程（文 → 图）擅长制造“强对齐、可控分布”，两者互补可显著提升数据的覆盖与可信度。




图 5-1 Auto-Evol 多模态合成数据闭环 Pipeline：数据初始化（含标注）-过滤-原子问题生成-增强与校验-回流重写。

(2) 数据初始化：统一格式与任务路由的前置条件 “数据初始化”的核心目标是将不同来源的原始材料整理为后续指令/QA 生成阶段可直接提取或参考的源信息池：包括可追溯的元信息（来源、分辨率、类别/词条等）、必要的路由标签，以及与任务相关、可被复用的结构化线索。这里的“源信息”不要求跨数据源完全同构，而是强调为生成提供可依赖的参照物。在实践中，初始化阶段通常会沉淀两类关键产物。其一是自动生成的结构化描述/要素，作为用于蒸馏的中间表征：以世界知识数据为例，初始化阶段往往会先为图片生成结构化 caption，并显式区分“画面可见信息”（主体、属性、关系、时空线索等）与“背景知识要点”（年份、导演、题材、所属系列等可核验事实）；该 caption 随后既可用于图文相关性过滤，也可作为知识要素抽取与 RecQA/KnowQA/FinalQA 构造时的主要上下文依据，从而把“图像与知识源”转化为可复用、可校验的中间表征。与此同时，为提升大模型蒸馏的可靠性，caption/要素抽取常配套引入固定输出格式与字段约束（例如先给出实体识别结论，再给出若干可核验事实）、自一致性采样/多次生成投票、以及“生成-判别”式复核（judge 过滤不一致或缺乏证据支撑的内容），将不确定与幻觉样本在数据侧前置淘汰。以词条“1917（电影）”为例，caption 会被要求同时给出图中“士兵/军装/战场环境”等可见证据与“2019、萨姆·门德斯、战争片”等知识要点；随后系统依据 caption 与词条的一致性保留高相关样本，并据此生成识别锚定的 RecQA 与需要知识调用/筛选的 KnowQA、FinalQA。其二是人工标注与上下文采集，作为高置信锚点：人工标注适用于需要像素级精确度、存在强歧义/同名消歧、或需要遵循严格规则与一致性约束的场景，其作用是为后续生成提供稳定锚点与可复核依据。以 GUI 任务为例，可沉淀候选控件集合、紧致 bbox、OCR 文本、控件可交互性/状态（如 Activated/Interactable/Filled）以及标签-控件绑定等关系信息，从而支撑 Grounding/Referring 等任务的可执行监督；以世界知识任务为例，可对词条集合进行边界校正与别名对齐、处理同名实体歧义，并对关键样本进行抽检复核，确保“图片 ↔ 词条 ↔ 知识”的对应关系可追溯、可验证。

(3) 过滤：相关性与准确性的第一道闸门 “过滤相关性、准确性”是合成数据可用性的核心保障，其目标是尽早剔除“错图错标/弱对齐/不可验证”的样本，避免噪声在后续指令生成与训练中被放大。以第4章为例，图片来自自动检索，天然会混入同名歧义、相似实体、无关插图等噪声；因此在进入 QA 构造前，系统会基于“图片 ↔ 词条”的匹配强度进行相关性评分（1-5 分），并要求输出简要理由与固定格式，便于程序解析与自动化处理。在阈值化过滤的同时，为兼顾覆盖率与长尾，流程通常会保留高分样本并对部分中等分样本进行抽样复核，从而在“尽可能保留潜在相关证据”与“抑制错配监督”之间取得平衡。

与之相比，SynthVLM 更偏向使用自动指标（如 CLIPScore、SSIM 等）对图文对齐度与图像质量进行强筛选^[10,20,66]，其优势在于可规模化、可重复；而世界知识任务中的相关性过滤更强调语义一致性与可解释性（尤其是同名消歧与实体锚定）。两者共同指向同一结论：过滤不仅是去噪，更是控制训练信号可信度与信息密度的关键环节。

(4) 任务导向的原子问题生成（三基础能力/三生成链路） 在 Auto-Evol 中，“把任意多模态任务统一分解为感知、理解、推理三类基础能力，并为每一类能力设计对应的数据生成链路和监督信号”。因此，三代理生成不仅是工程上的分工，更是多模态模型能力结构的抽象——其他任务数据（如 GUI 定位与交互、世界知识识别与问答、多轮对话、工具调用等）都可以视为三类能力的组合与不同权重的路由结果。

具体而言，Pipeline 中的三条生成链路可概括为：

- **感知链路 (Perception)**: 以图像为主要证据，生成可直接对齐到视觉区域/实体的监督信号（如 bbox、OCR 文本、实体识别锚定）。例如在 GUI 中，感知链路产出紧致 bbox 与文本对齐，使模型学会在密集小控件场景下稳定“指哪打哪”；在世界知识中，感知链路对应 RecQA：先把图片中的具体实例可靠地锚定到词条实体，解决“看见但叫不出名字/叫错名字”的问题。
- **理解链路 (Understanding)**: 在感知锚点基础上，生成高密度语义解释与可复用上下文（如结构化 caption、关系解释、背景知识片段），提升语义覆盖与可解释性。以世界知识为例，初始化阶段沉淀的结构化 caption 把“画面可见信息”与“背景知识要点”组织成稳定上下文，理解链路据此构造 KnowQA，将可泛化的事实知识与实体绑定；以 GUI 为例，理解链路对应 Referring 类数据：给定 bbox 输出控件功能/文本/属性及其与周边元素的关系，从而让模型学会“看懂”而不仅是“定位”。
- **推理链路 (Reasoning)**: 在“感知锚定 + 语义/知识上下文”之上，生成需要多步条件推断的监督信号，并尽可能加入过程性约束以避免短路学习。以世界知识为例，FinalQA 要求模型先识别实体再调用知识完成筛选/推断，并在加入 Think/CoT 后显著提升推理指标，说明推理链路必须提供“先识别再推理”的过程监督；以 GUI 为例，推理链路对应包含多步计划与工具调用约束的任务数据，使模型学习在页面状态、控件关系与目标约束下生成可执行的动作序列。

通过上述三链路路由，Auto-Evol 把“难任务”拆成“可控生成、可控校验”的组合单元：感知链路提供可对齐的锚点，理解链路提供可复用的语义/知识上下

文，推理链路提供过程性约束与可验证推断，从而系统性降低错配与幻觉传播，并提升数据的可迁移性与覆盖度。

(5) 数据增强：细粒度、难度、指令多样性的系统注入 Pipeline 中的“数据增强”可理解为对训练信号的三条系统性“加密”方向，它们既对应数据侧要解决的三类瓶颈，也对应模型希望被强化能力，即关注细节、攻克难题、与人交互的能力：

- 细粒度增强（对齐粒度 → 感知能力）：针对多模态数据常见的“对齐粒度不够/忽略长尾细节”问题，围绕图像中的次要物体、背景细节与空间关系补充监督，使模型学习到更细的视觉证据与文本描述之间的对应关系。MMEvol 的 *Fine-grained Perception Evolution* 提供了一个可操作框架^[19]：利用检测框等视觉约束，将问题生成从“主目标描述”扩展到“被忽略区域/长尾物体”的定向提问，从而减少“看见但不说/说错”的幻觉风险。对应到本文任务中，GUI 场景的小控件与小字体天然属于细粒度信息，补充紧致 bbox 与 OCR 对齐监督，本质上就是对感知链路的信息密度加密。
- 难度增强（推理密度 → 推理能力）：针对“指令复杂性不足/缺乏深度推理步骤”的问题，通过多步推理、条件约束与可执行步骤显式提升推理密度。例如可以将推理抽象为“视觉操作链”（如定位、OCR、存在性判断、计数/计算等原子操作），并要求在输出答案前生成可追踪的推理步骤，从而把“难题”转化为可校验的过程监督。本文在世界知识任务中对 FinalQA 加入 Think/CoT（要求先识别实体，再调用知识完成筛选/推断），并在实验中观察到推理指标显著提升，正体现了“过程性推理监督”对推理能力增强的关键作用。
- 指令多样性增强（交互覆盖 → 理解与指令遵循能力）：针对“指令形式单一/交互覆盖不足”的问题，将同一语义目标改写为多样化的交互形式（如结构化 JSON、代码片段、角色设定、多轮对话等），以提升模型对不同用户表达与输出约束的鲁棒性。MMEvol 的 *Interaction Evolution* 强调在保持视觉约束的前提下扩展输出格式与交互方式^[19]，避免仅做“文本复杂化”而脱离图像证据；在 Auto-Evol 中，该方向对应理解链路的格式多样化注入，使模型既学会“说对”，也学会“按要求说”。

(6) 数据校验：LLM-as-a-Judge + 工具/执行校验的多维验证 高质量合成数据必须“可验证”。更准确地说，数据校验就是对数据做评测：围绕“我们希望模型最终具备什么能力”，反向定义数据应满足的作用与特性，并在生成后用可操

作的评测准则筛选与修正数据分布。总之想要什么样的数据，就要用对应方法校验才能得到，例如这三类比较普遍的校验：

- 难度校验（过滤“过于简单”的样本）：若目标是让模型解决难题，则需要避免训练集中被大量“简单题”稀释。实践中可用能力较弱的模型或规则基线先行作答：若弱模型在不依赖关键视觉/知识证据的情况下即可轻易答对，则该样本更可能属于低难度或存在捷径，可降权、剔除或重写以提升推理密度。
- 正确性与可验证性校验（确保监督信号“对”）：若目标是让模型切实学会某项能力，则监督必须可靠。可用更强的模型进行一致性复核（例如答案唯一性、推理链条自洽、与图像证据相符），并对推理类样本引入工具/执行校验（如代码执行、规则验证、可解析约束检查）来验证最终答案与中间步骤的一致性，从源头抑制错误监督与幻觉传播。
- 覆盖与多样性校验（保证可泛化的交互学习）：若目标是提升交互与指令遵循鲁棒性，则数据需要在任务类型、表达方式与输出格式上足够多样。可通过分布统计与约束检查（任务路由占比、模板去重、格式合法性、长尾覆盖等）评估并调整数据，使模型既学会“答对”，也学会“按要求答”。

(7) 回流重写/重生成：闭环提升与分布自适应 当某类任务通过率持续偏低时，系统触发右侧“重写”回路：要么对指令/答案进行重写（保持图像不变），要么回流到“生成图片”分支重新合成更契合任务的图像，再进入流程。该闭环使数据系统具备“自我修复”的能力，避免一次性生成导致的质量不可控的同时也不要浪费以得倒的信息。

5.2.2 从两类任务实践到统一框架的归纳

如前文所述，当前多模态模型能力上限越来越受制于训练数据的质量、对齐与推理密度，并在真实落地中呈现出一系列“结构性”误差模式：例如对小目标与文字细节不稳定、视觉证据与语言描述绑定松散、以及在“先识别再推断”的任务上易出现短路映射或幻觉。对应这一瓶颈，本文采用“从精细可执行监督到可控推理监督，再到统一框架抽象”的递进路线：先在 GUI 任务中用强约束、可执行的像素级监督打牢感知与定位基座，再在世界知识任务中引入可验证对齐与过程性推理监督贯通“识别 → 知识 → 推断”，最终将两类实践中可复用的模块上升为统一的数据合成方法学。

需要强调的是，Auto-Evol 并非“从概念出发”的抽象框图，也不只是对两章工作的事后总结，而是建立在系统性相关工作调研与本文多模态数据/训练实

践之上的方法学抽象：一方面，ShareGPT4V、SynthVLM、MMEvol、Synthesize Step-by-Step 等工作分别从高密度对齐、反向数据工程、进化式增强与分步推理链合成等角度提供了可复用的模块化思想^[18-20,62]；另一方面，本文在 GUI 与世界知识两类高难任务的落地过程中沉淀了关于多源数据组织、结构化初始化/标注、中间表征、过程性监督与质控的工程经验。下面以两条主线作为代表性实例说明该框架的归纳来源。GUI 主线（第3章）以结构化初始化与细粒度标注为核心，将“截图”转化为可计算、可追溯的控件集合（bbox、OCR、状态向量、关系图谱），再围绕 Referring/Grounding 等任务生成可执行监督，并通过多源融合与质控迭代提升稳定性；该方法很好解决了“小目标/文字细节不稳定”与“语义-几何绑定松散”等结构性问题：用强约束的像素级锚点把模型输出绑定到可执行目标，强调“可执行定位”与“可解释语义”的双对齐，并体现了细粒度对齐与分层能力路由在复杂交互场景中的必要性。世界知识主线（第4章）则以实体锚定与知识注入为核心，通过“词条 → 图片 → caption → 相关性过滤 → RecQA/ KnowQA/FinalQA”建立从知识源到可学习多模态监督的转化链路，并通过带推理过程（Think/CoT）的 FinalQA 强化“先识别再推理”的可迁移推理策略；该方法针对“短路映射/幻觉”与“推理链路缺失”等问题：以 caption 作为可依赖中间表征提升可验证性，以分数化对齐过滤抑制错配噪声，并用过程监督把推理从黑箱答案转为可学习的链路，从而强调“可验证对齐”与“推理链路贯通”。除上述两类任务外，本文在多模态数据构造与训练中还沉淀了可跨任务复用的通用做法，例如：以统一的“源信息池”承接不同数据源与标注形态、以三基础能力链路统一组织监督信号、以及以“难度/正确性/覆盖多样性”为目标对数据进行评测式校验，这些实践与调研结论共同促成了 Auto-Evol 作为统一框架的可迁移性与可扩展性。综上，GUI 与世界知识两条主线在“任务形态”上差异显著，但其共同结构恰好对应 Auto-Evol 的闭环：数据源组织决定覆盖与可控性（真实收集与生成/反向对齐互补），结构化初始化沉淀可复用的源信息与锚点（如控件集合或 caption 中间表征），原子化任务拆解与路由把复杂能力分解为感知/理解/推理三类可监督单元（如 Referring/Grounding 或 RecQA/KnowQA/FinalQA），代理式增强提升信息密度与难度分布，多维过滤/评测式校验在数据侧前置约束正确性与可验证性，并通过回流重写/重生成将失败样本转化为下一轮迭代目标。由此，Auto-Evol 回答了第1章提出的核心问题：将“零散的一次性合成”升级为可控、可评测、可迭代的数据合成系统，使高信息密度、高对齐度与高推理密度的训练信号能够稳定产出与跨任务复用。

5.3 模块有效性验证

Auto-Evol 的关键模块并非凭经验堆叠，其必要性可在第3章（GUI）与第4章（世界知识）的实验结果中得到直接验证。下面从“模块 → 证据”的角度进行归因式总结。

(A) 多源融合与结构化监督的必要性（对应初始化（含标注）/过滤） 在 GUI 任务中，仅靠基线模型性能较低；引入开源清洗数据后指标显著提升，而进一步融合闭源精标数据后提升更为明显：如表3-2所示，Grounding F1 由 0.324 提升至 0.846，Referring F1 由 0.523 提升至 0.905。该结果表明，多源覆盖 + 结构化标注 + 质控能够显著提高定位与识别性能，是 Auto-Evol “数据初始化-协作标注-过滤”的直接实证。

(B) 中间表征与相关性过滤的必要性（对应 caption 与对齐校验） 在世界知识任务中，caption 不仅提供“更丰富的描述”，更作为可依赖的中间表征支撑相关性过滤与后续 QA 构造。实验一的结论指出：Image Caption 对识别有正向作用（表4-2，F1_Rec 从 28.1 提升至 31.4–33.1），说明“中间表征 + 对齐筛选”能够为实体锚定提供更稳健的训练信号，对应 Auto-Evol 中“过滤相关性、准确性”与“相关性校验”的设计动机。进一步地，第4章在图文相关性过滤环节给出量化证据：在随机抽取的 2000 条“图片-词条”样本上，若仅做相关/不相关二分类过滤，最终保留约 1009 条；引入基于 caption 的 1~5 相关性分数并保留 ≥ 3 分样本后，可保留约 1511 条，同时“几乎无幻觉”样本占比由 72.6% 提升至 80.3%，且“大部分幻觉”占比由 7.9% 降至 4.2%（表4-1）。这表明：caption 作为中间表征不仅提升了对齐判别的可解释性，也使分数化过滤能够在覆盖率与对齐可靠性之间取得更优平衡，从而为后续 RecQA/KnowQA/FinalQA 提供更干净的实体锚点与知识上下文。

(C) 显式推理过程数据对推理能力的显著增益（对应原子化/推理代理/执行校验） 第4章进一步揭示：仅监督最终答案的 FinalQA 可能诱发“短路映射”，导致推理指标提升不显著甚至下降；而当 FinalQA 加入简要推理过程（Think/CoT）并扩充数据分布后，final 相关指标出现显著提升。如表4-3所示，在 Chinese SimpleVQA 上，Ovis2.5_9B_think_part123 相对 Qwen2.5-VL-7B 在 F1_Final 上提升 11.9 个点（同时 F1_Rec 提升 16.1 个点），验证了“显式推理链路监督”对可迁移推理能力的关键作用。这一现象与 Auto-Evol 强调的“原子化任务拆解 + 推理代理生成 + 多维校验（含可执行/一致性校验）”相一致：通过过程性监督与可验证机制，才能在提升推理强度的同时抑制幻觉与短路学习。

5.4 Auto-Evol 在 GUI CUA 领域的实例化

GUI CUA 与第3章 GUI 在监督形式上的对比 尽管同属“GUI”大类，CUA 任务在监督形式上与第3章 Mobile UI 的 Referring/Grounding 有所不同：第3章 GUI（感知端）以单步、静态、像素级的 Referring/Grounding 监督为主，模型在一张截图上完成“指代识别”或“定位落地”，监督粒度为 bbox / OCR / 状态向量；而本章 GUI CUA（综合中段）则以多步、动态、可执行的操作链监督为主，模型在动态变化的桌面环境中完成“感知当前状态 → 规划下一步动作 → 执行 → 跟踪状态转移”的完整闭环，监督粒度为完整轨迹与可执行真实结果比对。因此，GUI CUA 实例化对应 Auto-Evol 框架在数据能力光谱综合中段的展开，同时涉及感知能力（控件状态识别）+ 推理能力（多步规划）+ 过程性监督（执行结果校验）三类需求的协同支撑。配合第3章（感知端）与第4章（推理端）的工作，三者共同覆盖数据能力光谱的两端与中段，形成对 Auto-Evol 框架可迁移性的工程证据。

为进一步验证 Auto-Evol 框架在更复杂多模态场景下的可迁移性与可扩展性，本文以该框架为方法学，在 GUI 计算机使用智能体（Computer Use Agent, CUA）领域提出了一个面向**可验证任务合成**的工程实例。该实例选取 OSWorld^[6]评测体系作为载体，以三个典型 LibreOffice 应用领域（Calc 电子表格、Impress 演示文稿、Writer 文字处理）为端到端验证载体，并已沿用同一套 Pipeline 骨架向 VSCode、Chrome 等扩展领域拓展（仅需替换领域特定的能力字典与 evaluator parser），通过 Pipeline 化的可验证任务自动生成系统，将“零散人工标注 CUA 任务”升级为“面向感知/理解/推理三类能力、可批量生产 + 可自动评测 + 可闭环迭代”的数据合成链路。与近期 EvoCUA^[34]通过可验证合成扩展 CUA 训练经验的整体思路一致，本实例在 Auto-Evol 视角下更强调数据侧的能力路由、过程性校验与跨领域复用。

5.4.1 流程概览与 Auto-Evol 模块对应

该 GUI CUA 实例由三个外部阶段（生成-提交-审计）与八个 Gate（G1-G8）组成的内部流程构成，可视为图5-1的 Auto-Evol 闭环在 CUA 场景下的具象化。下文按“框架模块 → 实例流程”逐项映射。

(1) 数据源接入与结构化初始化 → Capability 池 + Persona 池 + Phase 0 Sampler 对应 Auto-Evol 的“数据源”与“数据初始化”模块，在 GUI CUA 实例中由两个池子驱动：(a) capabilities.json——为每个领域显式定义的“原子能力字典”（如 Calc 的 85 个 cap：F1-F35 公式类、S1-S15 格式类、O1-O13 组织类、A1-A9 分析类、W1-W6 工作表类、E1-E5 编辑类等），每个 cap 均挂有元数据（描述、所需列类

型、执行优先级、互斥约束、对应 OSWorld evaluator 函数); (b) Persona 池——10 万条偏向 AI-exposed 职业 (计算机科学/数学/金融/商业/统计等) 的 ElitePersonas, 为业务皮提供可控的人设分布。Phase 0 Sampler 按链长分布 (如 40%/35%/25% 对应 1/2/3 链) 抽取 cap combo + persona, 并施加 mutex (互斥) /needs (依赖) 约束, 生成可直接进入下游 Pipeline 的结构化 record。该步骤与 Auto-Evol 中“沉淀可复用的源信息池与路由标签”形成同构。

(2) 任务导向的原子问题生成 → Phase A–C 三链路 对应 Auto-Evol 的“感知/理解/推理”三能力链路, 在 GUI CUA 实例中按“业务皮–操作–评测”三段式生成:

- Phase A (TaskSpec LLM, 对应理解链路): 以 persona 为上下文调用 LLM 生成业务表述 (topic / sheet_name / columns / n_rows / persona_flavor 等), 使任务具备真实业务场景的语义外壳。Gate 1 校验 schema 与合理性, 不通过即重做。
- Phase B–C (chain executability + base/GT 生成, 对应感知链路): 按 cap combo 逐步在 openpyxl / python-pptx / python-docx 等真实文档对象上施加确定性变换 (每个 cap 实现为 `transform(wb, ctx) -> trace_entry`), 并通过 `soffice --headless` 做 round-trip 消除原生格式差异; 最终生成 base 文件 (agent 的起始状态) 与 GT 文件 (agent 应达到的目标状态)。Gate 2–3 校验 cap 链可执行性、文件存在性以及 GT 与 base 的可见 diff。
- Phase D (evaluator deterministic 反推, 对应推理校验前置): 在 GT 确定后, 由代码按 cap 语义反推 OSWorld evaluator 配置 (17 类规则: sheet_data / check_cell / check_formula / style_range / compare_csv 等), 无需 LLM 参与, 从源头保证“评测即确定性的真值比对”, 对应 Auto-Evol “可执行/一致性校验”的最强形态。

(3) 数据增强 → Phase E Instruction LLM + 多样性变体 对应 Auto-Evol “细粒度/难度/指令多样性增强”中的“指令多样性增强”维度。在 GUI CUA 实例中由 Phase E 实现: 将业务皮、cap trace、GT inspect 与 anchor 集合喂给 LLM, 按 4 种指令风格 (natural_user 50% / specific_request 30% / verbose_business 15% / terse_command 5%) 与 3 种 micro-variants 组合 (共 $4 \times 3 = 12$ 个 prompt 槽位) 生成自然语 instruction, 使同一语义目标可被改写为多样化的交互形式。Gate 4 按“schema 合法 / anchor 出现 / 规则一致 / LLM-judge 通过”四重校验, 不通过即触发重写。

(4) 数据校验 → 8-Gate 体系 + 离线 evaluator 模拟 + L2 扰动 + 防泄漏 Gate 对应 Auto-Evol 中 “LLM-as-a-Judge + 工具/执行校验的多维验证”，但在 GUI CUA 实例中进一步以 “可执行 evaluator” 为核心：

- G7 (GT-on-GT smoke)：在生成的 GT 上跑 evaluator 期望 reward=1.0——若不通过，说明 evaluator 配置自相矛盾，drop。
- G8 (FN-attack)：构造 “反事实 agent 输出”（如把 GT 还原为 base、或施加 L2 扰动），期望 evaluator reward=0.0——若仍通过，说明 evaluator 过松、存在假阴风险，drop。
- G9 (covers_official anti-leakage)：对显式标记 “覆盖 OSWorld 官方任务” 的 cap，按 token-Jaccard 与 LCS 阈值过滤与官方 instruction / value 雷同的合成 task，防止训练评测泄漏，保证合成数据在评测体系上仍具备区分度。

G7-G9 合在一起，实现了 “数据生成阶段的自动评测式质控”，与 Auto-Evol 强调的 “评测式校验” 在工程上完全对应；其本质是把 “想要什么样的数据，就要用对应方法校验” 的原则前推至生成阶段，避免噪声进入训练。

(5) 回流重写/重生成 → Phase F-G + audit 反馈 对应 Auto-Evol 的 “失败回流重写/重生成”。每一 Gate 失败即触发对应 Phase 重做或 drop+resample（如 Phase A schema fail → 重做 A，Phase D' 校验 fail → drop）；所有 accepted record 聚合为 manifest.jsonl 与 task_registry.csv，再由 OSWorld sandbox (vela) 执行真实 agent rollout，运行结果通过 audit_<domain>.py 与 LLM-as-judge 生成 confusion matrix 与 per-cap reward 分布，反馈到下一轮 Pipeline 参数调整与 cap 优化。在三个 LibreOffice 领域上，本框架均实现 OSWorld 官方任务的 100% 覆盖率（Calc 47/47、Impress 47/47、Writer 23/23），具体的端到端训练增益见 5.4.3 节与表 5-1。该闭环即 Auto-Evol “以失败样本驱动下一轮迭代目标” 原则在 Agent 场景下的具象化。

5.4.2 与 Auto-Evol 在多模态合成场景下的差异化贡献

相比第3章与第4章以 “图片 +caption+QA” 为载体的合成场景，该 GUI CUA 实例在 Auto-Evol 统一框架下的差异化贡献体现在四点：

- 从语义对齐到行为可执行：监督信号从 “对图像证据的描述/问答” 扩展到 “对桌面文档/界面状态的可执行操作链”，使 Auto-Evol 的 “感知/理解/推理” 三链路得以在 “看-懂-做” 完整闭环中验证；

- 从 LLM 判别到代码确定性校验：通过把 evaluator 从 GT 反推为确定性规则（而非由 LLM 打分），实现了真正意义上的“工具/执行校验”，使 G7/G8 等 Gate 具备零 LLM 依赖、可重复的质控能力，显著降低了评测噪声与成本；
- 从单任务复用到跨领域模板复用：通过共享 `common/sampler_v2.py`、`common/task_registry.py`、`common/io_utils.py` 等基础设施，三个 LibreOffice 领域以及 VSCode、Chrome 等其他 GUI 领域可以复用同一套 Pipeline 骨架，仅需替换领域特定的 `capabilities.json + transformers + evaluator_parser`，体现了 Auto-Evol 作为统一框架在跨任务域上的可迁移性；
- 从单端验证到两端 + 中段全光谱覆盖：第3章与第4章分别覆盖数据能力光谱的感知端与推理端，本节的 GUI CUA 实例化进一步覆盖了感知 + 推理协同的综合中段（多步操作链 + 动态状态跟踪），使 Auto-Evol 框架在数据能力光谱的两端与中段三个代表性位置都获得了端到端验证，进一步说明了框架在跨任务域上的可迁移性。

该实例从工程层面表明：Auto-Evol 不仅适用于“图文/知识问答”等以 LLM-as-Judge 为主的多模态合成场景，亦可作为“GUI CUA 可验证任务合成”的方法学，为构建大规模、可自动评测的 Computer Use Agent 训练语料提供可复用工程范式，并与 OSWorld^[6]、EvoCUA^[34]等代表性工作形成互补与延伸。

5.4.3 基于 Auto-Evol 合成数据的端到端训练验证

为进一步验证 Auto-Evol 在 GUI CUA 实例化下所产合成数据对模型实际能力的提升效果，本文以前述 LibreOffice 三个领域（Calc/Impress/Writer）的可验证任务合成系统为数据源，开展端到端“合成数据 → 轨迹采集 → SFT 训练 → 评测”实验。

合成数据规模与构造流程 依托第5.4节描述的 Pipeline，在三个 LibreOffice 领域上共生成 900 条经 Gate 1–Gate 9 全链路过滤的可验证任务（`manifest.jsonl`），随后调用指导模型（teacher agent）在 OSWorld 可交互 Ubuntu 沙箱中对每个任务执行 rollout，仅保留与 GT 确定性 evaluator 比对 `reward=1.0` 的成功轨迹，最终得到 723 条高质量轨迹。考虑到长程多步轨迹直接作为监督信号易引入梯度稀释与上下文长度爆炸，本文对轨迹进行单步拆分：对一条长度为 T 的轨迹，将其展开为 T 个训练样本，每个样本以“该步之前的全部历史步骤”为上下文输入、以“当前步动作”为监督目标，从而保留多步规划语义的同时实现样本级精细化监

督。最终得到约 3 万条单步训练数据，用于对 Qwen3-VL-Think 基础模型进行有监督微调（SFT）。

评测设置 评测使用 OSWorld 官方的 LibreOffice 三个领域任务集合（Calc 47 题、Impress 47 题、Writer 23 题，共 117 题），以每题确定性 evaluator 真实运行得分（满分 1.0）累加为领域级 reward 总和，并将 3 个领域总和除以 117 得到总体准确率（overall accuracy，%）。所有评测均在与训练数据合成同构的 OSWorld 可交互沙箱中执行，保证训练分布与评测分布一致。

实验结果 如表5-1所示，经 Auto-Evol 合成数据训练后，Qwen3-VL-Think 模型在三个领域上均获得显著提升，总体准确率从 **40.8%** 提升至 **61.4%**（绝对增益 **+20.6 pt**）；其中 Calc 绝对得分增幅最大（+14.17，对应领域准确率由 23.0% 升至 53.2%），Impress 与 Writer 分别绝对 +5.89 与 +4.00（对应领域准确率分别提升 +12.5 pt 与 +17.4 pt），三个领域无回退。

表 5-1 基于 Auto-Evol GUI CUA 合成数据训练前后，Qwen3-VL-Think 在 OSWorld Libre-Office 三个领域上的 reward 对比。Calc/Impress/Writer 列为领域级 reward 绝对总和（满分 = 该领域任务数），Overall 为 3 领域总和占 117 题的总体准确率（%）。

Model	Calc (满分 47)	Impress (满分 47)	Writer (满分 23)	Overall (%, 满分 117)
Qwen3-VL-Think（原始）	10.83	23.96	13.00	40.8
+ Auto-Evol 合成数据 SFT（本文）	25.00	29.85	17.00	61.4
Δ （绝对）	+14.17	+5.89	+4.00	+20.6

该结果从端到端训练角度直接验证了：（1）Auto-Evol 生成的可验证任务能够通过教师模型 rollout 稳定地产出“成功且与 GT 对齐”的高质量轨迹（900 合成任务 → 723 成功轨迹，验证通过率约 80.3%），从源头印证了“可验证任务合成”对降低轨迹噪声的关键作用；（2）“单步拆分 + 历史上下文”的轨迹 → 训练数据转化策略能够把长程多步监督有效迁移到大模型 SFT 训练，单一 7B 级 Think 模型即可在总体准确率上获得 +20.6 pt 绝对增益；（3）来自三个 LibreOffice 领域的同质合成数据可在每个领域上同时取得正增益，体现了 Auto-Evol 作为统一框架在跨领域训练扩展上的实证可行性。

5.5 本章小结

本章围绕“数据质量成为瓶颈”的现实约束，提出并系统化阐释了 Auto-Evol 多模态数据合成框架。其核心意义在于：将以往零散、一次性的合成数据生成，升级为一个可路由、可评测、可闭环迭代的数据合成系统，从而稳定地产出高信息密度、高对齐度与高推理密度的训练信号。

具体贡献体现在三点：（1）统一能力视角——以感知/理解/推理三基础能力为坐标系，把不同任务的数据需求统一到三条生成链路与可复用监督信号上，避免“为每个任务重新设计一套数据体系”；（2）评测式质控——将数据校验显式定义为对数据的评测，围绕难度、正确性/可验证性与覆盖多样性进行筛选与分布修正，降低错配监督与幻觉传播风险；（3）闭环可持续迭代——通过过滤、增强、校验与回流重写把失败样本转化为下一轮优化目标，使数据分布能够随任务瓶颈自适应演化。

框架的有效性在后续章节得到量化支撑：在 GUI 任务中，多源融合与结构化监督显著提升 Grounding/Referring 性能（表3-2）；在世界知识任务中，引入中间表征与过程性推理监督（Think/CoT）带来推理指标的显著增益（表4-3）。在此基础上，本章5.4节进一步将 Auto-Evol 实例化到 GUI CUA 场景，基于 OSWorld 评测体系^[6]构建可验证任务合成的工程系统，在 LibreOffice 三个领域上完成端到端验证，并已沿用同一套 Pipeline 骨架向 VSCode、Chrome 等扩展领域拓展，与 EvoCUA^[34]等代表性工作形成互补；其端到端训练验证（5.4.3节，表5-1）进一步表明，基于本框架生成的 900 合成任务 → 723 成功轨迹 → 3 万条单步训练数据可将 Qwen3-VL-Think 在 OSWorld LibreOffice 三个领域上的总体准确率由 40.8% 提升至 61.4%（+20.6 pt 绝对增益）。

综上，Auto-Evol 既为第3章与第4章提供统一的数据工程底座，沉淀可复用的闭环 Pipeline；又通过 GUI CUA 端到端 SFT 实验给出量化证据，为多模态数据合成在更多任务域（无论位于能力光谱何处）的复用与扩展提供可迁移的方法学基础。

第 6 章 结论

6.1 研究总结

本文围绕“多模态数据合成框架”这一主线展开研究，针对多模态大语言模型（MLLM）训练中“数据质量成为瓶颈”的现实问题，探索如何以可控、可迭代、可验证的方式生产高质量训练数据，从而稳定提升模型在真实场景中的关键能力。相比仅依赖互联网抓取图文对或高成本人工标注，本文强调以数据工程视角把合成数据生成升级为系统化流程：在覆盖真实分布的同时提供强对齐与高推理密度监督，并通过多维质控抑制错配与幻觉传播。本文沿**数据能力光谱**的三个代表性位置（感知端 / 推理端 / 综合中段）形成“**两端实证 → 共通抽象 → 综合中段端到端验证**”的研究路径。

两端实证（第3章 + 第4章）。其一是**感知端**：面向用户图形界面（GUI）的屏幕理解与可执行定位能力提升（第3章）。针对控件密集、文字细小与状态易变等难点，通过多源数据融合、结构化初始化、混合标注与属性补全、任务化构造与质控迭代，沉淀高精度、强约束、可校验的 Referring/Grounding 监督基座。其二是**推理端**：面向世界知识的识别-知识对齐-推理贯通能力提升（第4章）。构建可操作的世界知识类别框架与端到端数据 Pipeline，以 caption 作为中间表征支撑相关性过滤与 QA 构造，并通过引入带推理过程（Think/CoT）的 FinalQA 缓解短路映射，强化“先识别再推理”的可迁移推理能力；同时结合增强与对齐校验，提升“视觉证据 ↔ 知识事实”绑定的可信度。

共通抽象 + 综合中段端到端验证（第5章）。在两端实践基础上，本文进一步抽象提出 **Auto-Evol** 多模态数据合成框架，将以往单步的“图 → 文/问答”生成升级为包含数据源组织与结构化初始化、质量过滤、任务路由与原子问题生成、代理式生成与进化增强、多维校验与失败回流的闭环流水线。该框架以“感知/理解/推理”三基础能力为统一坐标系，将不同任务的数据需求抽象为可复用的生成链路，并将“数据校验”明确为评测式验证，从而在数据侧前置控制训练信号的可信度、对齐度与推理密度。在框架抽象之上，本文进一步将 Auto-Evol 实例化到综合中段——计算机使用智能体（Computer Use Agent, CUA）场景下的 GUI 任务（GUI CUA，多步操作链 + 动态状态跟踪）：依托 OSWorld^[6] 评测体系，在 LibreOffice 三个领域（Calc/Impress/Writer）上构建可验证任务合成的工程系统并完成端到端验证，同时已沿用同一套 Pipeline 骨架向 VSCode、Chrome 等扩

展领域拓展；端到端“合成任务 → 教师智能体轨迹采集 → 单步拆分 → 监督微调 (SFT)”实验给出量化证据——基于 900 合成任务、723 成功轨迹与 3 万条单步训练数据，将 Qwen3-VL-Think 在 OSWorld LibreOffice 三个领域上的总体准确率由 40.8% 提升至 61.4%（绝对增益 +20.6 pt），并与 EvoCUA^[34]等代表性工作形成互补与延伸。

综上，本文从任务瓶颈出发形成数据工程落地范式，并在此之上完成统一框架抽象与综合中段端到端验证：以闭环数据合成系统支撑不同任务域的合成数据构造，以可验证的监督信号驱动多模态模型能力的稳定提升。Auto-Evol 既为第3章（感知端）与第4章（推理端）两条主线的数据工程实践提供了系统化的方法学归纳与抽象，又通过 GUI CUA 端到端 SFT 实验给出了可量化的能力增益证据，为后续在更多任务域中的复用与扩展提供了可迁移的工程基础。

6.2 主要成果与创新点

本文的主要成果与创新点沿数据能力光谱的三个代表性位置展开（顺序与第3章 → 第4章 → 第5章一致），可概括为以下三个方面：

- 感知端：面向 GUI 的结构化监督与可执行定位数据体系：面向控件密集、文字细小与状态易变的 GUI 场景，构建多源互补语料与 bbox / OCR / 关系 / 状态等结构化监督信号，并结合相应训练策略提升 Referring/Grounding 的稳定性与可执行性（第3章），构成数据能力光谱感知端的工程实证。
- 推理端：面向世界知识的可控对齐与推理贯通数据体系：建立可扩展的知识类别框架与“词条 → 图片 → caption → 过滤 → RecQA/KnowQA/FinalQA”的 Pipeline，以 caption 作为中间表征提升对齐可信度，并通过 Think/CoT 形式的过程监督缓解短路映射，增强“先识别再推理”的可迁移推理能力（第4章），构成数据能力光谱推理端的工程实证。
- Auto-Evol 多模态数据合成框架（共通抽象 + 综合中段端到端验证）：将合成数据从一次性生成升级为可路由、可评测、可闭环迭代的数据合成系统，形成覆盖数据源接入、结构化初始化、质量过滤、任务路由与原子问题生成、数据增强、多维校验与失败回流重写/重生成的闭环 Pipeline，并以“感知/理解/推理”三基础能力统一组织监督信号（第5章）；进一步将该框架实例化到综合中段的 GUI 计算机使用智能体 (CUA) 场景——CUA 任务需要“感知 + 推理 + 状态跟踪”协同，依托 OSWorld^[6]评测体系在 LibreOffice 三个领域（Calc/Impress/Writer）上构建可验证任务合成工程系统并完成端到端验证，并已沿用同一套 Pipeline 骨架向 VSCode、Chrome 等其他领域拓展；端到端 SFT 实验取得 Qwen3-VL-Think 在 LibreOffice 三个领域上总

体准确率 **40.8%→61.4% (+20.6 pt)** 的显著增益，与 EvoCUA^[34]等工作形成方法学互补，为多模态数据合成在更多任务域的复用提供可迁移的工程基础。

6.3 不足与展望

尽管本文围绕多模态数据合成框架进行了系统探索并取得一定效果，但仍存在若干局限，有待后续进一步研究与完善。

6.3.1 研究不足

对自动化判别与强模型生成的依赖仍较强。在相关性过滤、质量打分、重写与推理链路生成等环节，流程往往需要依赖能力更强的模型作为生成器或判别器。尽管这种“LLM-as-a-Generator/Judge”的框架显著提升了自动化程度，但其成本、稳定性与偏置问题仍会影响数据分布与最终训练效果。

可验证性与工具化校验仍有提升空间。本文强调数据应可验证，但在部分任务（尤其是开放域世界知识）中，完全自动、可执行的事实核验仍较困难；当知识源不一致或存在时效差异时，如何构造严格唯一、可核验的监督信号仍需要更强的检索与证据链机制。

对合成数据“幻觉/错配”的传播机理与抑制策略仍不充分。尽管本文通过多维过滤与校验降低噪声，但在开放式生成（如 caption/CoT/解释链路）中仍可能产生看似合理但与视觉证据不一致的幻觉内容，并在闭环回流与再生成中被“强化”或扩散；如何构建更强的证据约束、可执行一致性校验与基于不确定性的拦截机制，以系统性降低错误监督累积，仍有待进一步研究。

合成数据的“典型特征”偏置可能损伤多样性与泛化。当数据构造过度依赖固定模板、局部高频 N-gram 或单一风格的生成策略时，样本容易呈现可辨识的“合成痕迹”，导致语言分布收缩、表达同质化，进而削弱对长尾表述与跨场景的覆盖；未来需要在去模式化生成、分布匹配约束与多样性度量/正则方面进一步完善，以避免“看似干净但不够多样”的数据偏差。

任务覆盖与框架泛化尚未完全展开。本文以 GUI 与世界知识两条任务线验证框架有效性，但 Auto-Evol 作为通用框架仍需要在更多模态与场景中验证，例如视频理解、时序交互、具身智能、多模态工具调用等，以进一步检验其可迁移性与可扩展性。

评测体系仍存在不足。当前评测主要围绕特定基准与任务指标进行，尚缺乏与数据合成闭环严格对齐的、覆盖“对齐度/推理密度/可执行性/安全性”的综合评价体系，导致部分数据改动的收益难以被快速、稳定地观测与归因。

6.3.2 展望

更强的证据链与工具校验：从“LLM 判别”走向“可执行验证”。未来可将检索增强（RAG）、结构化知识库与可执行工具（如规则验证、代码执行、可解析约束检查）更深度地嵌入数据校验环节，构建“证据 → 结论”的可追溯链路，以系统性降低幻觉与错误监督。

面向多模态 Agent 的数据闭环：从静态监督到交互式自改进。GUI 场景天然具备可交互与可执行特征，未来可引入环境回放与任务执行反馈，把“模型输出是否可执行/是否达成目标”作为校验信号，形成更接近真实 Agent 训练的闭环数据合成与评测体系。

框架扩展到更多模态与任务域。将 Auto-Evol 扩展到视频、音频、三维与具身场景，探索时序一致性、跨帧对齐、长程规划等问题下的原子化任务拆解与质控策略，以验证框架在更复杂场景下的通用性。

效率与规模化：降低生成成本并提升覆盖。未来可研究更高效的生成与筛选策略（如分层采样、主动学习式采样、低成本模型预筛 + 高成本模型复核的级联机制），在保证质量的同时扩大长尾覆盖并降低整体数据合成成本。

数据治理与安全约束。随着合成数据规模扩大，数据的版权合规、隐私保护与安全对齐将更加关键。未来可在数据初始化与过滤阶段引入更系统的治理策略与安全评测，确保数据合成链路在可控与可审计的前提下运行。

参考文献

- [1] OPENAI. Gpt-4o system card[A/OL]. 2024. <https://arxiv.org/abs/2410.21276>.
- [2] Gemini Team. Gemini: A family of highly capable multimodal models[A/OL]. 2023. <https://arxiv.org/abs/2312.11805>.
- [3] BAI S, CHEN K, LIU X, et al. Qwen2.5-vl technical report[A/OL]. 2025. <https://arxiv.org/abs/2502.13923>.
- [4] LIU H, LI C, WU Q, et al. Visual instruction tuning[C]//Advances in Neural Information Processing Systems: Vol. 36. 2024.
- [5] WU Z, WU Z, XU F, et al. Os-atlas: A foundation action model for generalist gui agents[A/OL]. 2024. <https://arxiv.org/abs/2410.23218>.
- [6] XIE T, ZHANG D, CHEN J, et al. OSWorld: Benchmarking multimodal agents for open-ended tasks in real computer environments[C/OL]//Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track. 2024. <https://arxiv.org/abs/2404.07972>.
- [7] ZHANG C, HE S, QIAN J, et al. Large language model-brained gui agents: A survey[A/OL]. 2024. <https://arxiv.org/abs/2411.18279>.
- [8] SCHUHMANN C, VENCU R, BEAUMONT R, et al. Laion-5b: An open large-scale dataset for training next generation image-text models[A/OL]. 2022. <https://arxiv.org/abs/2210.08402>.
- [9] BYEON M, PARK B, KIM H, et al. Coyo-700m: Image-text pair dataset[EB/OL]. 2022. <https://github.com/kakaobrain/coyo-dataset>.
- [10] HESSEL J, HOLTZMAN A, FORBES M, et al. Clipscore: A reference-free evaluation metric for image captioning[C/OL]//Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing. 2021: 7514-7528. <https://aclanthology.org/2021.emnlp-main.595/>. DOI: 10.18653/v1/2021.emnlp-main.595.

- [11] WANG Y, KORDI Y, MISHRA S, et al. Self-instruct: Aligning language models with self-generated instructions[C/OL]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 13484-13508. <https://aclanthology.org/2023.acl-long.754>.
- [12] MUKHERJEE S, MITRA A, JAWAHAR G, et al. Orca: Progressive learning from complex explanation traces of gpt-4[A]. 2023.
- [13] CHENG K, SUN Q, CHU Y, et al. Seeclick: Harnessing gui grounding for advanced visual gui agents[C/OL]//Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL). 2024. <https://arxiv.org/abs/2401.10935>.
- [14] DU Y, LI C, GUO R, et al. Pp-ocr: A practical ultra lightweight ocr system[A/OL]. 2020. <https://arxiv.org/abs/2009.09941>.
- [15] LI Y, DU Y, ZHOU K, et al. Evaluating object hallucination in large vision-language models[C/OL]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2023. <https://arxiv.org/abs/2305.10355>.
- [16] MARINO K, RASTEGARI M, FARHADI A, et al. OK-VQA: A visual question answering benchmark requiring external knowledge[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2019: 3195-3204. <https://arxiv.org/abs/1906.00067>.
- [17] ZHANG Z, ZHANG A, LI M, et al. Multimodal chain-of-thought reasoning in language models[J/OL]. Transactions on Machine Learning Research, 2024. <https://arxiv.org/abs/2302.00923>.
- [18] CHEN L, LI J, DONG X, et al. Sharegpt4v: Improving large multi-modal models with better captions[A/OL]. 2023. <https://arxiv.org/abs/2311.12793>.
- [19] LUO R, ZHANG H, CHEN L, et al. Mmevol: Empowering multimodal large language models with evol-instruct[A/OL]. 2024. <https://arxiv.org/abs/2409.05840>.
- [20] LIU Z, LIANG H, LI B, et al. Synthvlm: Towards high-quality and efficient synthesis of image-caption datasets for vision-language models[C/OL]//Proceedings

- of the 33rd ACM International Conference on Multimedia. ACM, 2025. DOI: [10.1145/3746027.3758222](https://doi.org/10.1145/3746027.3758222).
- [21] DEKA B, HUANG Z, FRANZEN C, et al. Rico: A mobile app dataset for building data-driven design applications[C/OL]//Proceedings of the 30th Annual ACM Symposium on User Interface Software and Technology (UIST). 2017. DOI: [10.1145/3126594.3126651](https://doi.org/10.1145/3126594.3126651).
- [22] GAO L, ZHANG L, WANG S, et al. Mobileviews: A million-scale and diverse mobile gui dataset[A/OL]. 2024. <https://arxiv.org/abs/2409.14337>.
- [23] LI G, BAECHLER G, TRAGUT M, et al. Learning to denoise raw mobile ui layouts for improving datasets at scale[C/OL]//Proceedings of the 2022 CHI Conference on Human Factors in Computing Systems (CHI). 2022. <https://doi.org/10.1145/3491102.3502042>.
- [24] CHEN W, CUI J, HU J, et al. Guicourse: From general vision language models to versatile gui agents[A/OL]. 2024. <https://arxiv.org/abs/2406.11317>.
- [25] LIU X, ZHANG X, ZHANG Z, et al. Ui-e2i-synth: Advancing gui grounding with large-scale instruction synthesis[A/OL]. 2025. <https://arxiv.org/abs/2504.11257>.
- [26] CHEN D, HUANG Y, WU S, et al. Gui-world: A video benchmark and dataset for multimodal gui-oriented understanding[A/OL]. 2024. <https://arxiv.org/abs/2406.10819>.
- [27] SCHWENK D, KHANDELWAL A, CLARK C, et al. A-OKVQA: A benchmark for visual question answering using world knowledge[C/OL]//European Conference on Computer Vision (ECCV). 2022. <https://arxiv.org/abs/2206.01718>.
- [28] CHEN Y, HU H, LUAN Y, et al. Can pre-trained vision and language models answer visual information-seeking questions?[C/OL]//Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP). 2023. <https://arxiv.org/abs/2302.11713>.
- [29] CHANG Y, NARANG M, SUZUKI H, et al. Webqa: Multihop and multimodal qa[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2022: 16474-16483. <https://arxiv.org/abs/2109.00590>.

- [30] LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C/OL]//Advances in Neural Information Processing Systems (NeurIPS). 2020. <https://arxiv.org/abs/2005.11401>.
- [31] YAO S, ZHAO J, YU D, et al. React: Synergizing reasoning and acting in language models[C/OL]//International Conference on Learning Representations (ICLR). 2023. <https://arxiv.org/abs/2210.03629>.
- [32] WEI J, KARINA N, CHUNG H W, et al. Measuring short-form factuality in large language models[A/OL]. 2024. <https://arxiv.org/abs/2411.04368>.
- [33] WEI J, WANG X, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[C]//Advances in Neural Information Processing Systems: Vol. 35. 2022: 24824-24837.
- [34] XUE T, PENG C, HUANG M, et al. EvoCUA: Evolving computer use agents via learning from scalable synthetic experience[A/OL]. 2026. <https://arxiv.org/abs/2601.15876>.
- [35] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778. <https://arxiv.org/abs/1512.03385>.
- [36] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[C/OL]//International Conference on Learning Representations (ICLR). 2021. <https://arxiv.org/abs/2010.11929>.
- [37] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International Conference on Machine Learning. PMLR, 2021: 8748-8763.
- [38] JIA C, YANG Y, XIA Y, et al. Scaling up visual and vision-language representation learning with noisy text supervision[A/OL]. 2021. <https://arxiv.org/abs/2102.05918>.
- [39] ALAYRAC J B, DONAHUE J, LUC P, et al. Flamingo: a visual language model for few-shot learning[C/OL]//Advances in Neural Information Processing Systems (NeurIPS): Vol. 35. 2022: 23716-23736. https://proceedings.neurips.cc/paper_files

- [es/paper/2022/hash/960a172bc7fbf0177ccccbb411a7d438-Abstract-Conference.html](https://arxiv.org/abs/2022.09.01).
- [40] LI J, LI D, SAVARESE S, et al. Blip-2: Bootstrapping language-image pre-training with frozen image encoders and large language models[C]//International Conference on Machine Learning. PMLR, 2023: 19730-19742.
- [41] LIU H, LI C, LI Y, et al. Improved baselines with visual instruction tuning[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops. 2024: 26296-26306.
- [42] LI J, LI D, XIONG C, et al. Blip: Bootstrapping language-image pre-training for unified vision-language understanding and generation[C/OL]//International Conference on Machine Learning (ICML). 2022. <https://arxiv.org/abs/2201.12086>.
- [43] DAI W, LI J, LIU D, et al. Instructblip: Towards general-purpose vision-language models with instruction tuning[A/OL]. 2023. <https://arxiv.org/abs/2305.06500>.
- [44] CHEN X, WANG X, CHANGPINYO S, et al. Pali: A jointly-scaled multilingual language-image model[A/OL]. 2022. <https://arxiv.org/abs/2209.06794>.
- [45] Qwen Team, Alibaba Cloud. Qwen3-vl: Multimodal large language model series [EB/OL]. 2025. <https://github.com/QwenLM/Qwen3-VL>.
- [46] Xiaomi LLM-Core Team. Mimo-vl technical report[A/OL]. 2025. <https://arxiv.org/abs/2506.03569>.
- [47] MASRY A, LONG D X, TAN J Q, et al. Chartqa: A benchmark for question answering about charts with visual and logical reasoning[C]//Findings of the Association for Computational Linguistics: ACL 2022. 2022: 2263-2279.
- [48] LIU F, EISENSCHLOS J M, PICCINNO F, et al. Deplot: One-shot visual language reasoning by plot-to-table translation[C]//Findings of the Association for Computational Linguistics: ACL 2023. 2023: 10724-10732.
- [49] LIU F, PICCINNO F, KRICHENE S, et al. Matcha: Enhancing visual language pretraining with math reasoning and chart derendering[C]//Proceedings of the 61st Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). 2023: 12756-12770.

- [50] LEE K, JOSHI M, TURC I, et al. Pix2struct: Screenshot parsing as pretraining for visual language understanding[C]//International Conference on Machine Learning. PMLR, 2023: 18893-18912.
- [51] PODELL D, ENGLISH Z, LACEY K, et al. Sdxl: Improving latent diffusion models for high-resolution image synthesis[A]. 2023.
- [52] LI Y, YANG Z, GUO Y, et al. Droidbot: A lightweight ui-guided test input generator for android[C/OL]//Proceedings of the 39th International Conference on Software Engineering Companion (ICSE-C). IEEE, 2017: 23-26. https://yuanchun-li.github.io/static/files/ICSE2017_DroidBot.pdf. DOI: 10.1109/ICSE-C.2017.8.
- [53] SHI T, KARPATHY A, FAN L, et al. World of bits: An open-domain platform for web-based agents[A/OL]. 2017. <https://arxiv.org/abs/1703.05424>.
- [54] DENG X, GU Y, ZHENG B, et al. Mind2web: Towards a generalist agent for the web[C/OL]//Advances in Neural Information Processing Systems (NeurIPS). 2023. <https://arxiv.org/abs/2306.06070>.
- [55] ZHOU S, XU F F, ZHU H, et al. Webarena: A realistic web environment for building autonomous agents[A/OL]. 2023. <https://arxiv.org/abs/2307.13854>.
- [56] WANG X, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[C/OL]//International Conference on Learning Representations (ICLR). 2023. <https://arxiv.org/abs/2203.11171>.
- [57] YAO S, YU D, ZHAO J, et al. Tree of thoughts: Deliberate problem solving with large language models[C/OL]//Advances in Neural Information Processing Systems (NeurIPS). 2023. <https://arxiv.org/abs/2305.10601>.
- [58] YANG Z, LI L, WANG J, et al. Mm-react: Prompting chatgpt for multimodal reasoning and action[A/OL]. 2023. <https://arxiv.org/abs/2303.11381>.
- [59] SURIS D, MENON S, VONDRICK C. Vipergpt: Visual inference via python execution for reasoning[A/OL]. 2023. <https://arxiv.org/abs/2303.08128>.
- [60] OUYANG L, WU J, JIANG X, et al. Training language models to follow instructions with human feedback[C]//Advances in Neural Information Processing Systems: Vol. 35. 2022: 27730-27744.

-
- [61] MITRA A, DEL CORRO L, ZHENG G, et al. Agentinstruct: Toward generative teaching with agentic flows[A/OL]. 2024. <https://arxiv.org/abs/2407.03502>.
- [62] LI Z, JASANI B, TANG P, et al. Synthesize step-by-step: Tools, templates and llms as data generators for reasoning-based chart vqa[A/OL]. 2024. <https://arxiv.org/abs/2403.16385>.
- [63] SHUMAILOV I, SHUMAYLOV Z, ZHAO Y, et al. The curse of recursion: Training on generated data makes models forget[A/OL]. 2023. <https://arxiv.org/abs/2305.17493>.
- [64] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: Unified, real-time object detection[C/OL]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 779-788. <https://arxiv.org/abs/1506.02640>.
- [65] CHEN Z, WU J, WANG W, et al. Internvl: Scaling up vision foundation models and aligning for generic visual-linguistic tasks[C/OL]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). 2024. <https://arxiv.org/abs/2312.14238>.
- [66] WANG Z, BOVIK A C, SHEIKH H R, et al. Image quality assessment: From error visibility to structural similarity[J/OL]. IEEE Transactions on Image Processing, 2004, 13(4): 600-612. DOI: [10.1109/TIP.2003.819861](https://doi.org/10.1109/TIP.2003.819861).
- [67] BAI J, BAI S, YANG S, et al. Qwen-vl: A frontier large vision-language model with versatile abilities[A]. 2023.
- [68] WANG Y, MISHRA S, ALIPOORMOLABASHI P, et al. Supernaturalinstructions: Generalization via declarative instructions on 1600+ tasks[C]//Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. 2022: 5085-5109.

复旦大学 学位论文独创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。论文中除特别标注的内容外，不包含任何其他个人或机构已经发表或撰写过的研究成果。对本研究做出重要贡献的个人和集体，均已在论文中作了明确的声明并表示了谢意。本声明的法律结果由本人承担。

作者签名：_____ 日期：_____

复旦大学 学位论文使用授权声明

本人完全了解复旦大学有关收藏和利用博士、硕士学位论文的规定，即：学校有权收藏、使用并向国家有关部门或机构送交论文的印刷本和电子版本；允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其它复制手段保存论文。涉密学位论文在解密后遵守此规定。

作者签名：_____ 导师签名：_____ 日期：_____